

Grado en Ingeniería Electrónica Industrial y Automática
Curso 2020-2021

Trabajo Fin de Grado

“Análisis de Clasificación del Terreno mediante Imagen Satelital”

Carlos García-Mauriño Villanueva

Tutor/es

Daniel Amigo Herrero

Leganés, 2021

RESUMEN

Este proyecto trata de establecer un sistema repetible mediante el cual se obtenga un resultado que supla una necesidad. En este caso, la necesidad consiste en contar con información sobre las características de los terrenos que puede resultar muy útil para hacer un mejor uso de los mismos y de su explotación, utilizando para ello un método que no existe en la actualidad. Esta información puede tener diferentes usos, como pueden ser:

- Análisis de vegetación: tipos, localización y área ocupada.
- Estudio del impacto medioambiental a lo largo del tiempo.
- Estudio del clima (a grandes rasgos, con poca exactitud).
- Estudio de consecuencias de catástrofes naturales.
- Definición de área de campos de cultivo.
- Análisis del desarrollo urbano (crecimiento de ciudades).

Por lo tanto, el objetivo de este proyecto será presentar un análisis de clasificación de los terrenos que permita, por ejemplo, que un agricultor pueda realizar una clasificación de sus cultivos dentro de sus tierras para optimizar su explotación, o que un cartógrafo pueda observar el análisis realizado para poder llegar a la conclusión de qué método de clasificación es mejor para diseñar sus mapas.

Para realizar de manera correcta este proyecto, será necesario familiarizarse con los conceptos, establecer un proceso completo de clasificación y explicar cómo realizar una correcta discusión de los resultados. Para cumplir estos objetivos, este TFG dedicará un apartado al estado del arte, en el que se explicarán las imágenes satelitales, softwares de manipulación de imágenes y métodos de clasificación. A continuación, se explicará en profundidad el proceso de clasificación de una imagen satelital. Finalmente, se elegirán una serie de ejemplos sobre los cuáles se realizará la clasificación del terreno y se procederá a un análisis de resultados.

Palabras clave: terreno, imagen satelital, clasificación, diseño de sistema, aplicaciones.

ABSTRACT

This project will try to establish a repeatable system through which we will obtain a result that fills a need. In this case, the need is to obtain information about terrain that cannot be accessed nowadays, because if it wasn't the case this project would not be needed. This information has different applications, such as:

- Vegetation analysis: types, location and occupied area.
- Study of environmental impact over time.
- Study of climate (broadly speaking, with little accuracy).
- Study of consequences of natural catastrophes.
- Definition of the area of cultivated fields.
- Analysis of urban development (growth of cities).

Therefore, the objective of this project will be for a farmer to be able to perform a classification of his crops within his land, but also for a cartographer to be able to observe the analysis performed in order to reach the conclusion of which classification method is better to design his maps.

In order to perform this project correctly, it will be necessary to become familiar with the concepts, establish a complete classification process, and explain how to perform a correct discussion of the results. To accomplish these points, this TFG will deal with a state-of-the-art section, in which satellite images, image manipulation software and classification methods will be explained. Then, the classification process of a satellite image will be explained in depth. Finally, a series of examples will be chosen on which the terrain classification and analysis of results will be performed.

Keywords: terrain, satellite imagery, classification, system design, applications.

ÍNDICE DE CONTENIDOS

1	INTRODUCCIÓN	1
1.1	MOTIVACIÓN.....	2
1.2	OBJETIVOS	3
1.3	ESTRUCTURA DEL DOCUMENTO	4
2	ESTADO DEL ARTE.....	7
2.1	INTRODUCCIÓN SATÉLITES	7
2.1.1	LANDSAT 8	7
2.1.2	SENTINEL-1.....	8
2.1.3	SENTINEL-2.....	10
2.2	INTRODUCCIÓN SOFTWARE GIS	11
2.2.1	GRASS GIS.....	13
2.2.2	GVSIG.....	13
2.2.3	QGIS.....	14
2.2.4	ArcGIS.....	15
2.3	TIPOS DE CLASIFICACIÓN.....	15
2.3.1	CLASIFICACIÓN MANUAL	16
2.3.2	CLASIFICACIÓN HÍBRIDA	16
2.3.3	CLASIFICACIÓN DIGITAL/NUMÉRICA	17
2.3.3.1	TIPOS.....	18
2.3.3.1.1	LINEAR DISCRIMINANT ANALYSIS	18
2.3.3.1.2	TREE.....	20
2.3.3.1.3	K-NN.....	23
2.3.3.1.4	RANDOM FOREST	25
2.4	SOFTWARES DE CLASIFICACIÓN	27

2.4.1	LAND COVER CLASSIFIER	28
2.4.2	ENVI.....	28
2.4.3	SEMI AUTOMATIC CLASSIFICATION PLUGIN	29
3	DISEÑO DE LA SOLUCIÓN	31
3.1	SELECCIONAR ESCENARIO	32
3.2	ESTABLECIMIENTO DE ROIS	33
3.3	ALGORITMO DE LA CLASIFICACIÓN	34
3.4	DISEÑO DE LA MUESTRA	34
3.5	VALIDACIÓN DE LA CLASIFICACIÓN	36
3.6	EXTRACCIÓN DE RESULTADOS	36
3.7	VALORACIÓN DE RESULTADOS.....	37
4	EJECUCIÓN DE LA SOLUCIÓN	39
4.1	SELECCIONAR ESCENARIO	39
4.2	ESTABLECIMIENTO DE ROIS.....	42
4.3	ALGORITMO DE CLASIFICACIÓN.....	43
4.3.1	CLASIFICACIÓN POR ALGORITMO DE DISTANCIA MÍNIMA	43
4.3.2	CLASIFICACIÓN POR ALGORITMO DE MÁXIMA PROBABILIDAD	45
4.3.3	CLASIFICACIÓN POR ALGORITMO DE ÁNGULO ESPECTRAL ..	46
4.4	CLASIFICACIÓN DE PÍXELES.....	47
4.4.1	CASO 1	48
4.4.1.1	DISTANCIA MÍNIMA.....	49
4.4.1.2	MÁXIMA PROBABILIDAD	50
4.4.1.3	ÁNGULO ESPECTRAL.....	51
4.4.2	CASO 2	52
4.4.2.1	DISTANCIA MÍNIMA.....	53
4.4.2.2	MÁXIMA PROBABILIDAD	54

4.4.2.3	ÁNGULO ESPECTRAL.....	55
4.4.3	CASO 3	56
4.4.3.1	DISTANCIA MÍNIMA.....	57
4.4.3.2	MÁXIMA PROBABILIDAD	58
4.4.3.3	ÁNGULO ESPECTRAL.....	59
4.5	DISEÑO DE LA MUESTRA	60
4.5.1	CASO 1	62
4.5.1.1	DISTANCIA MÍNIMA.....	62
4.5.1.2	MÁXIMA PROBABILIDAD	63
4.5.1.3	ÁNGULO ESPECTRAL.....	64
4.5.2	CASO 2	65
4.5.2.1	DISTANCIA MÍNIMA.....	65
4.5.2.2	MÁXIMA PROBABILIDAD	66
4.5.2.3	ÁNGULO ESPECTRAL.....	67
4.5.3	CASO 3	68
4.5.3.1	DISTANCIA MÍNIMA.....	68
4.5.3.2	MÁXIMA PROBABILIDAD	69
4.5.3.3	ÁNGULO ESPECTRAL.....	70
4.6	VALIDACIÓN DE LA CLASIFICACIÓN	71
4.7	EXTRACCIÓN Y VALORACIÓN DE RESULTADOS	73
4.7.1	CASO 1	73
4.7.1.1	OBJETIVOS.....	73
4.7.1.2	DISTANCIA MÍNIMA.....	74
4.7.1.3	MÁXIMA PROBABILIDAD	74
4.7.1.4	ÁNGULO ESPECTRAL.....	75
4.7.2	CASO 2	75

4.7.2.1	OBJETIVOS.....	75
4.7.2.2	DISTANCIA MÍNIMA.....	76
4.7.2.3	MÁXIMA PROBABILIDAD	76
4.7.2.4	ÁNGULO ESPECTRAL.....	77
4.7.3	CASO 3	78
4.7.3.1	OBJETIVO.....	78
4.7.3.2	DISTANCIA MÍNIMA.....	78
4.7.3.3	MÁXIMA PROBABILIDAD	79
4.7.3.4	ÁNGULO ESPECTRAL.....	79
4.8	DISCUSIÓN DE RESULTADOS	80
5	PLANIFICACIÓN Y PRESUPUESTO.....	83
5.1	PLANIFICACIÓN	83
5.2	PRESUPUESTO	84
6	CONCLUSIONES Y LINEAS DE INVESTIGACIÓN	87
6.1	CONCLUSIONES	87
6.2	LÍNEAS DE INVESTIGACIÓN	88
6.3	OPINIÓN PERSONAL	88
7	BIBLIOGRAFÍA.....	91

ÍNDICE DE TABLAS

Table 1. Bandas del satélite Landsat8	7
Table 2. Bandas del satélite Sentinel 2	10
Table 3. Comparación entre tipos de clasificación digital supervisada.....	27
Table 4. Comparación de softwares de clasificación	29
Table 5. Leyenda y área de la clasificación por distancia mínima (Caso 1)	49
Table 6. Leyenda y área de la clasificación por máxima probabilidad (Caso 1).....	50
Table 7. Leyenda y área de la clasificación por ángulo espectral (Caso 1).....	51
Table 8. Leyenda y área de la clasificación por distancia mínima (Caso 2)	53
Table 9. Leyenda y área de la clasificación por máxima probabilidad (Caso 2).....	54
Table 10. Leyenda y área de la clasificación por ángulo espectral (Caso 2).....	55
Table 11. Leyenda y área de la clasificación por distancia mínima (Caso 3)	57
Table 12. Leyenda y área de la clasificación por máxima probabilidad (Caso 3).....	58
Table 13. Leyenda y área de la clasificación por ángulo espectral (Caso 3).....	59
Table 14. Ejemplo de obtención de píxeles totales	61
Table 15. Ejemplo de obtención de píxeles por clase.....	61
Table 16. Obtención de píxeles a clasificar totales para caso 1 (Distancia mínima)	62
Table 17. Obtención de píxeles a clasificar por clases para caso 1 (Distancia mínima)	62
Table 18. Obtención de píxeles a clasificar totales para caso 1 (Máxima probabilidad)	63
Table 19. Obtención de píxeles a clasificar por clases para caso 1 (Máxima probabilidad)	63
Table 20. Obtención de píxeles a clasificar totales para caso 1 (Ángulo espectral).....	64
Table 21. Obtención de píxeles a clasificar por clases para caso 1 (Ángulo espectral) .	64
Table 22. Obtención de píxeles a clasificar totales para caso 2 (Distancia mínima)	65
Table 23. Obtención de píxeles a clasificar por clases para caso 2 (Distancia mínima)	65
Table 24. Obtención de píxeles a clasificar totales para caso 2 (Máxima probabilidad)	66
Table 25. Obtención de píxeles a clasificar por clases para caso 2 (Máxima probabilidad)	66
Table 26. Obtención de píxeles a clasificar totales para caso 2 (Ángulo espectral).....	67
Table 27. Obtención de píxeles a clasificar por clases para caso 2 (Ángulo espectral) .	67

Table 28. Obtención de píxeles a clasificar totales para caso 3 (Distancia mínima)	68
Table 29. Obtención de píxeles a clasificar por clases para caso 3 (Distancia mínima)	68
Table 30. Obtención de píxeles a clasificar totales para caso 3 (Máxima probabilidad)	69
Table 31. Obtención de píxeles a clasificar por clases para caso 3 (Máxima probabilidad)	69
Table 32. Obtención de píxeles a clasificar totales para caso 3 (Ángulo espectral).....	70
Table 33. Obtención de píxeles a clasificar por clases para caso 3 (Ángulo espectral) .	70
Table 34. Datos de precisión obtenidos para el caso 1 (Distancia mínima).....	74
Table 35. Datos de precisión obtenidos para el caso 1 (Máxima probabilidad).....	74
Table 36. Datos de precisión obtenidos para el caso 1 (Ángulo espectral)	75
Table 37. Datos de precisión obtenidos para el caso 2 (Distancia mínima).....	76
Table 38. Datos de precisión obtenidos para el caso 2 (Máxima probabilidad).....	76
Table 39. Datos de precisión obtenidos para el caso 2 (Ángulo espectral)	77
Table 40. Datos de precisión obtenidos para el caso 3 (Distancia mínima).....	78
Table 41. Datos de precisión obtenidos para el caso 3 (Máxima probabilidad).....	79
Table 42. Datos de precisión obtenidos para el caso 3 (Ángulo espectral)	79
Table 43. Organización del presupuesto del proyecto.....	85
Table 44. Tabla de siglas	97

ÍNDICE DE FIGURAS

Figure 1. Esquema del funcionamiento del sistema SAR en el satélite Sentinel 1	9
Figure 2. Ejemplo de clasificación mediante métodos LDA y PCA	20
Figure 3. Ejemplo de clasificación mediante método TREE	21
Figure 4. Ejemplo de clasificación mediante método K-NN	24
Figure 5. Esquema de clasificación mediante método Random Forest	26
Figure 6. Esquema de la solución	31
Figure 7. Opciones de filtros en la obtención de imágenes de las misiones Sentinel	41
Figure 8. Visualización y descarga de imágenes Sentinel	42
Figure 9. Ejemplo de establecimiento de ROIs en el caso 3	43
Figure 10. Esquema de clasificación de una muestra mediante ángulo espectral	47
Figure 11. Imagen satelital de caso 1 (Madrid)	48
Figure 12. Clasificación de caso 1 mediante distancia mínima	49
Figure 13. Clasificación de caso 1 mediante máxima probabilidad	50
Figure 14. Clasificación de caso 1 mediante ángulo espectral	51
Figure 15. Imagen satelital de caso 2 (Córcega)	52
Figure 16. Clasificación de caso 2 mediante distancia mínima	53
Figure 17. Clasificación de caso 2 mediante máxima probabilidad	54
Figure 18. Clasificación de caso 2 mediante ángulo espectral	55
Figure 19. Imagen satelital de caso 3 (Dodge City)	56
Figure 20. Clasificación de caso 3 mediante distancia mínima	57
Figure 21. Clasificación de caso 3 mediante máxima probabilidad	58
Figure 22. Clasificación de caso 3 mediante ángulo espectral	59
Figure 23. Ejemplo de píxel aleatorio para validación manual de la clasificación	71
Figure 24. Diagrama de Gantt del desarrollo del trabajo	84
Figure 25. Matriz de confusión de caso 1 (Distancia mínima)	99
Figure 26. Matriz de confusión de caso 1 (Máxima probabilidad)	100
Figure 27. Matriz de confusión de caso 1 (Ángulo espectral)	101
Figure 28. Matriz de confusión de caso 2 (Distancia mínima)	102
Figure 29. Matriz de confusión de caso 2 (Máxima probabilidad)	103

Figure 30. Matriz de confusión de caso 2 (Ángulo espectral).....	104
Figure 31. Matriz de confusión de caso 3 (Distancia mínima).....	105
Figure 32. Matriz de confusión de caso 3 (Máxima probabilidad)	106
Figure 33. Matriz de confusión de caso 3 (Ángulo espectral).....	107

1 INTRODUCCIÓN

La superficie terrestre cambia lenta pero inexorablemente. Obviamente, los mapas hechos hace 100 años no son los mismos que los que se utilizan ahora, pero quizá no es tan obvio descubrir que los mapas hechos hace 15 años tampoco se acercan demasiado a la realidad. Por ejemplo, en la isla de Maranhao (Brasil) se perdió un 25 % de la vegetación entre 1992 y 2010 debido a un proceso de urbanización [1]. Este descubrimiento no era obvio al principio, pero el uso de imágenes satelitales permitió a los investigadores valorar el verdadero daño causado en la isla.

Este ejemplo es muy específico, pero también es muy representativo de lo que está ocurriendo en la actualidad, y más en un momento de constante evolución y cambio. Se calcula que únicamente un 3% de la superficie terrestre no se ha visto afectada por la humanidad de una manera u otra, lo que nos aporta una idea del impacto al que está expuesto el planeta.

En otro caso, un grupo de investigación ha colaborado con el gobierno de Argelia para desarrollar un sistema en tiempo real que utiliza imágenes satelitales para determinar la cantidad de píxeles “lluviosos” y, con ello, poder tener una mayor precisión a la hora de predecir el tiempo [2].

Estas imágenes, además, tienen ciertos atributos que nos facilitan ver la superficie terrestre con gran detalle: las bandas espectrales. El espectro visible por el ser humano es solo una fracción del espectro electromagnético, que cubre todas las longitudes de las ondas electromagnéticas. La utilización de cámaras multispectrales por parte de muchos satélites nos permite ver una misma imagen con muchas capas de diferentes longitudes de onda, lo que le da profundidad y detalle a la misma.

Este proyecto tratará en detalle diferentes softwares y métodos de clasificación para crear un proceso repetible de clasificación de imágenes por satélite que incluya, desde la detección de una necesidad específica, hasta la obtención e interpretación de datos de precisión.

1.1 MOTIVACIÓN

Realizar la clasificación del terreno a partir de una imagen satelital es una herramienta poco usada fuera del ámbito de la cartografía o estudio geográfico de la tierra. Esto es parte de un tema o concepto que no se trata demasiado en la actualidad fuera de ese campo, por lo que es fácil rechazar la idea de realizar una clasificación argumentando que es necesario ser un experto o estar muy familiarizado con el tema para poder clasificar la imagen satelital de un terreno de manera precisa.

Esto es verdad en parte: por un lado, tener conocimiento de la materia permite ser más flexible en las clasificaciones y poder razonar qué se hace y por qué se hace. Sin embargo, también es posible pensar en una clasificación del terreno como proceso, formado por una serie de pasos que, seguidos correctamente, te llevan a un resultado satisfactorio.

Por lo tanto, una de mis principales motivaciones es demostrar que se puede simplificar un proyecto de temática compleja transformándolo en un proceso accesible y repetible que aporte valor al usuario que lo realice. En este caso, el proceso abarca identificar la necesidad del usuario, conseguir una clasificación del terreno eficaz y facilitar una metodología de valoración de resultados subjetiva, tras la cual se consigue obtener el resultado deseado.

Otra de las motivaciones que me ha llevado a elegir este tema para mi TFG tiene que ver con la utilidad del mismo de cara a otros proyectos relacionados con la materia. Así, la posibilidad de que este trabajo pueda llegar a ser utilizado en estudios medioambientales o de medición de consecuencias de catástrofes naturales le aporta un valor “social” que va más allá de la mera obtención del grado en Ingeniería.

1.2 OBJETIVOS

En cuanto a los objetivos que se esperan cumplir a la finalización del proyecto, se encuentran los siguientes:

- Desarrollar un informe muy detallado y actualizado de los métodos de clasificación de terrenos, de sus usos y del funcionamiento del software que lo hace posible.
- Explicar diferentes satélites y las características de las imágenes obtenidas de ellos, con la intención de poder ser utilizadas en softwares de manipulación y clasificación de imágenes satelitales.
- Tratar en profundidad el funcionamiento de algunos softwares de clasificación usados actualmente y sus modos de análisis de las imágenes. En esta explicación viene incluida el enseñar lo que es QGIS y su función en la clasificación y estudio de terreno.
- Mostrar posibles usos de esta clasificación y hacer accesible dicha clasificación a cualquier persona, teniendo en cuenta el coste y el software utilizado.
- Diseñar una solución que se pueda seguir paso a paso, tratando todas las partes del proceso de manera clara y concisa.
- Realizar un análisis de las clasificaciones obtenidas, con una consiguiente conclusión sobre el método más efectivo según la clasificación.
- Demostrar los conocimientos y capacidades adquiridas por el alumno realizando este trabajo a lo largo del estudio de su grado. Gracias a esta demostración, conseguirá obtener finalizar sus estudios y obtener su título de grado si asegura las condiciones necesarias de este proyecto.

1.3 ESTRUCTURA DEL DOCUMENTO

El orden en el que se tratan los conceptos y procesos en este TFG es de gran importancia, puesto que, si no se hace un seguimiento del guion, es fácil confundir términos o fallar a la hora de realizar una clasificación cualquiera. Por ello se procederá a estructurar y definir cada punto tratado en el proyecto:

- Estado del Arte: se trata de un capítulo paraguas que agrupa todos los conocimientos previos del tema de cara a entender de manera global la clasificación de una imagen satelital. Dentro de este capítulo nos encontramos una introducción a satélites (Landsat 8, Sentinel 1 y Sentinel 2), una introducción al software GIS (GRASS, GvSIG, QGIS, ArcGIS), una explicación de los métodos de clasificación (manual, híbrida, digital) y diferentes tipos (LDA, TREE, K-NN, RF) y, por último, una explicación de algunos softwares de clasificación de imágenes satelitales (SAC, LCC, ENVI)
- Diseño de la solución: en este apartado se explica el sistema completo que permite al usuario realizar una clasificación de imagen satelital desde su inicio. Incluye diferentes pasos: seleccionar escenarios, establecer ROIs, aplicar el algoritmo de clasificación, etc.
- Ejecución de la solución: en este apartado se aplica el sistema diseñado en el apartado anterior para realizar la clasificación de 3 terrenos diferentes, finalizando el proceso con una discusión sobre los resultados obtenidos.
- Planificación y presupuesto: en este capítulo se describen las diferentes partes del proyecto y su duración, además de utilizar un diagrama de Gantt para establecer una línea cronológica del desarrollo de este TFG. En este apartado también se habla del coste total del proyecto con sus consecuentes justificaciones.
- Conclusiones y línea de investigación: en este apartado se realizan 3 funciones, análisis de cumplimiento de los objetivos descritos al principio del TFG, explicación de otros usos o campos para la tecnología utilizada en este proyecto y una opinión personal sobre el tema del TFG en general.
- Bibliografía: aquí aparecen todos los estudios y herramientas que se han citado a lo largo del TFG.

- Anexos: formado por un anexo de siglas y por otro de los datos de precisión obtenidos en el apartado de ejecución de la solución.

2 ESTADO DEL ARTE

2.1 INTRODUCCIÓN SATÉLITES

Un aspecto muy importante de este proyecto es la comprensión del funcionamiento del sistema que obtiene las imágenes satelitales. En las últimas décadas se ha avanzado mucho en este campo, mandando muchos satélites al espacio con características que lo hacen más o menos adecuado dependiendo de la situación.

Este TFG se centra en la clasificación del terreno según imágenes obtenidas de satélites. Entre los satélites que más se ajustan a esta necesidad se encuentran el Landsat 8, el Sentinel 1(A y B) y el Sentinel 2 (A y B).

2.1.1 LANDSAT 8

El satélite Landsat 8 es el heredero del Landsat 7 y fue lanzado en California en febrero de 2013. Su método de obtención de imágenes se basa en 2 sensores: el sensor OLI (Operational Land Imager) y el TIRS (Thermal Infrared Sensor). Estos 2 sensores componen las 11 bandas espectrales que reconoce el satélite, 9 del OLI (0,433-1,390 μm) y 2 del TIRS (10,30-12,50 μm).

Table 1. Bandas del satélite Landsat8

Bandas	Longitud de onda (μm)	Resolución (m)
Banda 1 – Aerosol costero	0,43 - 0,45	30
Banda 2 – Azul	0,45 - 0,51	30
Banda 3 – Verde	0,53 - 0,59	30
Banda 4 – Rojo	0,64 - 0,67	30
Banda 5 – Infrarrojo cercano (NIR)	0,85 - 0,88	30
Banda 6 – SWIR 1	1,57 – 1,65	30
Banda 7 – SWIR 2	2,11 – 2,29	30
Banda 8 – Pancromático	0,50 – 0,68	15
Banda 9 – Cirrus	1,36 – 1,38	30
*Banda 10 – Infrarrojo térmico (TIRS) 1	10,60 – 11,19	100
*Banda 11 – Infrarrojo térmico (TIRS) 2	11,50 – 12,51	100

Como en la mayoría de los casos, las imágenes obtenidas por el Landsat 8 no son perfectas. Sin embargo, se pueden utilizar herramientas externas para mejorar la calidad. El uso de un DEM (Digital Elevation Model) ayuda a obtener una imagen radiométrica y geoméricamente corregida. En cuanto a los problemas generados por reflejos o dispersiones atmosféricas, se pueden utilizar métodos como el QUAC (Quick Atmospheric Correction) que se basa en el uso de la reflectancia media del material en una escena determinada.

Aunque la posibilidad de utilizar los datos de todas las bandas puede ser tentador, al final acaba siendo contraproducente. No todas las bandas nos dan información útil y pueden tener resoluciones espaciales diferentes, lo que puede generar imágenes inexactas. Analizando nuestro problema, podemos hipotetizar que las bandas de mayor utilidad serán las RGB. Esta conclusión será aplicable a todos los satélites. En el caso del Landsat 8, las bandas que corresponden a RGB tienen una resolución de 30 m [3].

2.1.2 SENTINEL-1

La misión Sentinel-1 está compuesta por dos satélites, el Sentinel-1A fue lanzado el 3 de abril de 2014 y el Sentinel-1B, el 25 de abril de 2016. Ambos despegaron en la Guayana francesa. Para poder proporcionar imágenes de toda la Tierra, ambos se encuentran separados a 180° siguiendo una órbita a 693 km de altura. Su vida útil se ha determinado en 7 años.

El lanzamiento del Sentinel 1 responde a la necesidad de obtener imágenes de lugares de difícil acceso, como pueden ser océanos o desiertos inhóspitos. Por lo tanto, su principal uso es el de la monitorización del tráfico tanto marítimo como terrestre. Para obtener esta información, el Sentinel 1 dispone de un radar de apertura sintética (SAR) a una frecuencia de 5,405 GHz [4].

El SAR es un tipo de radar que, a grandes rasgos, transforma escenarios 3D en imágenes 2D mediante la reconstrucción de objetos. El radar está formado por 2 sistemas, el sistema receptor y el sistema emisor. El sistema emisor se encarga de enviar ondas de radio de una determinada frecuencia al espacio del que quieres obtener la reconstrucción 2D. El

sistema receptor está formado por una antena que se encarga de recibir las ondas de radio que se reflejan al rebotar con objetos. Generalmente, la imagen obtenida será de mejor resolución cuanto mayor sea el radio de la antena.




Figure 1. Esquema del funcionamiento del sistema SAR en el satélite Sentinel 1

El sistema SAR tiene su origen en la elaboración de mapas de determinadas zonas al acoplarlo en aviones o drones. Esto produce una imagen a pequeña escala. La misión Sentinel 1 consta de antenas de 12 m de largo, lo que le permite elaborar imágenes de grandes extensiones de terreno.

Analizando nuestro problema, podemos concluir que uno de los aspectos más importantes a la hora de clasificar el terreno es que la imagen obtenida sea lo más fiable posible. Aunque alguna imagen concreta obtenida por el Sentinel 1 puede ser de ayuda, la resolución obtenida por este sistema no es la más adecuada para tratar el tema del que hablamos en este proyecto.

2.1.3 SENTINEL-2

La misión Sentinel-2 está compuesta por dos satélites, el Sentinel-2A fue lanzado el 23 de junio de 2015 y el Sentinel-1B, en marzo de 2017. Ambos despegaron en la Guayana francesa. Para poder proporcionar imágenes de toda la Tierra, ambos se encuentran separados a 180° siguiendo una órbita a 786 km de altura. Su vida útil se ha determinado en 7 años [5].

El Sentinel-2 forma parte de las misiones de la Agencia Espacial Europea y tiene el objetivo de continuar y mejorar las misiones que llevan a cabo los proyectos Spot (francés) y Landsat (estadounidense). A grandes rasgos, entre estas misiones encontramos análisis de los Glaciares, aplicaciones agrícolas (como la vigilancia de las tierras de cultivo) o el seguimiento de la vegetación/bosques.

Lo que le permite conseguir todo esto al Sentinel-2 es la obtención de imágenes a gran resolución. A su vez, estas imágenes son producto de un instrumento multiespectral (MSI) que funciona con una tecnología de sensor de barrido transversal. Esta tecnología se basa en la colocación de una línea de sensores de manera transversal al recorrido del satélite, de esta manera se absorbe la luz reflejada en la zona a estudiar píxel a píxel, consiguiendo obtener una imagen de la zona estudiada al final de dicho “barrido”.

Este MSI ofrece datos de 13 bandas espectrales situadas en la zona infrarroja visible (VNIR) y en la zona infrarroja de onda corta (SWIR), como se muestra a continuación. La frecuencia de las ondas varía entre 442,2-2202,4 nm.

Table 2. Bandas del satélite Sentinel 2

Bandas	Longitud de onda (μm)	Resolución (m)
Banda 1 – Aerosol costero	0,43 - 0,45	60
Banda 2 – Azul	0,45 - 0,52	10
Banda 3 – Verde	0,54 - 0,57	10
Banda 4 – Rojo	0,65 - 0,68	10
Banda 5 – Infrarrojo cercano (NIR)	0,69 - 0,71	20
Banda 6 – Infrarrojo cercano (NIR)	0,73 - 0,74	20
Banda 7 – Infrarrojo cercano (NIR)	0,77 - 0,79	20
Banda 8 – NIR	0,78 - 0,90	10

Bandas	Longitud de onda (μm)	Resolución (m)
Banda 8A – Infrarrojo cercano (NIR)	0,85 – 0,87	20
Banda 9 – Vapor de agua	0,93 – 0,95	60
Banda 10 – Cirrus-SWIR	1,36 – 1,39	60
Banda 11 – SWIR	1,56 – 1,65	20
Banda 12 – SWIR	2,10 – 2,28	20

Tras un intenso análisis de las opciones posibles, podemos concluir que, aunque será útil el uso de imágenes obtenidas del Sentinel-1 o el Landsat-8 para la aplicación en distintos clasificadores, el satélite mejor preparado y que más se ajusta a nuestras necesidades será el Sentinel-2.

2.2 INTRODUCCIÓN SOFTWARE GIS

En la actualidad, los softwares de manipulación de imágenes satelitales más potentes son propiedad de empresas privadas u organismos militares. Sin embargo, esto no significa que no existan herramientas de funcionalidad parecida y que son accesibles a cualquier tipo de usuario.

Al mismo tiempo que se lanzaban satélites y naves al espacio, también se desarrollaban el software y los métodos de análisis de la información que estos elementos nos proporcionaban. En esta línea destacan herramientas como GRASS GIS, QGIS (ambos del grupo OSGEO) y GvSIG.

Estos programas, aunque diseñados por personas o compañías distintas, tienen algo en común: los 3 son GIS (Geographic Information System). Además, los GIS llevan siendo utilizados durante décadas en materia de apoyo a recolección de datos, análisis y visualización de información geoespacial e investigación científica. Desde que se desarrolló el primer software GIS en los 60 como parte de un programa de inteligencia del ejército americano, este campo no ha dejado de crecer. De hecho, expertos valoraban el sector GIS en 5,33 billones de dólares en 2016, y se espera que se duplique ese valor de cara a 2023.

Durante los últimos 50 años, los GIS han sido utilizados en gran cantidad de ámbitos: geología, meteorología, hidrología... Pero uno de los campos que más se ha aprovechado de estos programas es el de la geografía, ya que las posibilidades que se abren cuando aplicas el uso de los GIS a una imagen obtenida de un satélite o de una aeronave son casi ilimitadas. No hace falta más que ver una herramienta que muchos de nosotros consideramos esencial: Google Maps. Aunque simple, Google Maps es un gran ejemplo de lo que se puede conseguir fusionando datos espaciales y un software adecuado.

GIS, como muchas otras herramientas, es producto directo del avance del ser humano en campos computacionales. Lo que GIS ha conseguido en 50 años es mucho más que lo que la raza humana había conseguido en los miles de años anteriores. Esto es debido a la aparición de las bases de datos, que nos permiten almacenar y manipular gran cantidad de información. En este caso, la información almacenada consiste en mapas e imágenes geoespaciales: GIS es capaz de asignar un punto geográfico a cada píxel de cada mapa e imagen, de manera que si modificas algo dentro del GIS, también modificas el mapa en cuestión [6].

Esto es posible mediante la utilización por parte de GIS de capas, llamadas “temas”. Cada capa contiene una categoría específica de información, pueden ser carreteras, bosques... o puede ir por píxeles. Al superponer una capa por encima de otra, se consigue una imagen más fiable con cada capa. Esto es lo que ocurre con las bandas satelitales, al introducir una imagen tipo GeoTIFF (bandas de diferentes frecuencias) se puede observar claramente qué clase de información contiene cada banda, obteniendo la imagen original al superponer todas ellas.

Sin embargo, aunque se acaba de hablar de las similitudes y generalidades que todos los sistemas GIS poseen, también pueden tener diferencias. Para profundizar este punto, voy a hablar de los programas de software que he mencionado anteriormente (GRASS GIS, GvSIG y QGIS) y de ArcGIS, cuya principal diferencia con los otros es que está producido y comercializado de manera privada.

2.2.1 GRASS GIS

GRASS es un GIS de uso libre abierto al público en 2008. Como se ha mencionado antes, se trata de uno de los proyectos de la fundación OSGEO. GRASS (Geographic Resources Analysis Support System) tiene un gran rango de funcionalidades y aplicaciones. Puede manejar información 2D y 3D, ya sea en formato ráster o vector, y ofrece técnicas de visualización y algoritmos de modelado geoespacial muy avanzados. Consiste en más de 300 módulos en Unix, cada uno de ellos con capacidad de memoria y de manejo de errores. La mayoría de librerías están escritas en POSIX (siguiendo ANSI C) aunque algunas están escritas en C++ o Python [7].

Una de las opciones más interesantes que ofrece GRASS es la capacidad de explotación de los sistemas actuales multinúcleos para poder aplicar los llamados algoritmos paralelos. En su inicio, los sistemas que usaban GIS tenían ciertos límites computacionales debido a las limitaciones en la tecnología. Esto significaba poder usar solo 1 módulo cada vez. La mejora de la tecnología y el desarrollo de software como el MPI (Message-Passing Interface), permite el almacenamiento de la memoria de manera paralela, de modo que se pueden usar varios módulos al mismo tiempo para obtener mejores resultados.

2.2.2 GVSIG

GvSIG es un GIS que fue iniciado en 2004. Su principal propulsor fue el gobierno de la Comunidad Valenciana, dentro de un proceso de migración hacia el uso de software libre, con apoyo de la Unión Europea. El GvSIG (Generalitat Valenciana Sistema de Información Geográfica) es un software de almacenaje y manejo de información geográfica con gran precisión. Su licencia de distribución es del tipo GNU GPLv3. En cuanto a sus especificaciones técnicas, GvSIG funciona en los sistemas operativos habituales y la gran mayoría de sus módulos están hechos en lenguaje Java [8].

Un aspecto importante que caracteriza a GvSIG es su capacidad de implementación de servicios OGC. El OGC (Open Geospatial Consortium) es una organización internacional que guía el desarrollo de estándares y especificaciones para servicios geoespaciales [9].

Entre sus competencias se encuentra el manejo de un proceso de consenso global que permite la normalización de la información geoespacial y, al mismo tiempo, la interoperabilidad entre diversas aplicaciones. Entre los estándares utilizados por GvSIG podemos encontrar, por ejemplo, el WMS (Web Map Services) que define cómo se deben generar mapas de forma dinámica, representando la información geográfica como un archivo de imagen digital (PNG, JPEG, GIF).

2.2.3 QGIS

QGIS es, quizás, el software de manipulación de información geoespacial más versátil de todos los mencionados. Es parte de los proyectos de OSGEo, junto con GRASS GIS, y fue también lanzado al público en 2008. QGIS (Quantum Geographic Information System) está disponible en todos los sistemas operativos, incluyendo BSD y Android, y opera bajo licencia GNU GPL. El lenguaje de programación usado es el Python, aunque algunas librerías se encuentran en C++.

QGIS no es el software más preciso ni el más rápido, pero si es el más libre y el más polivalente. La gran cantidad de plugins diseñados por la comunidad que permite usar lo convierte en un programa muy versátil y usado para tareas muy diversas. Además, puede trabajar con otros programas para potenciar sus capacidades, por ejemplo, un uso muy común del QGIS es el uso de su interfaz de usuario (GUI) en otro programa como puede ser GRASS, aprovechando todas las funcionalidades de este último de una manera mucho más cómoda [10].

De hecho, este trabajo de investigación sobre algunos de los GIS más populares es necesario en este proyecto, puesto que será necesaria una mesa de trabajo en la que manejar la información obtenida de las imágenes satelitales de las que hablábamos anteriormente. Tras un detenido análisis, QGIS es la herramienta que tiene más potencial y que es más fácil de usar por parte del usuario, así que tiene sentido que sea la que usemos para manipular los archivos GeoTIFF obtenidos del Sentinel-2.

2.2.4 ArcGIS

ArcGIS es el nombre que recibe el conjunto de servicios relacionados con la manipulación de imágenes satelitales lanzados en 1999 por la empresa ESRI. Entre estas herramientas que se pueden aplicar sobre imágenes satelitales se encuentran: tratamiento, diseño, captura, edición, publicación, impresión... Además, la familia ArcGIS está formada por un gran número de programas (Pro, Online, Server y Mobile) cada uno con pequeñas diferencias con respecto al resto [11].

Lo más destacable de ArcGIS es la cantidad de extensiones que permite utilizar. Algunas de ellas son el Network Analyst (para cálculo y trabajo con rutas de transporte), Spatial Analyst (con un gran número de herramientas relacionadas con el análisis espacial de datos), 3D Analyst (para poder analizar datos SIG en un escenario tridimensional) o el Geostatistical Analyst (para poder realizar análisis geoestadísticos).

2.3 TIPOS DE CLASIFICACIÓN

Este proyecto tiene como objetivo analizar los métodos de clasificación de terreno accesibles a cualquier usuario actualmente para intentar obtener una conclusión sobre cuál es más preciso. Sin embargo, no podemos hablar de programas o plugins clasificadores sin antes hablar de métodos de clasificación.

Para hablar de métodos de clasificación, sin embargo, antes es importante hacer notar que no hay una manera global de diferenciarlos. Según la variable que tengamos en cuenta (precisión, con o sin ayuda humana, rapidez...) obtendremos diferentes clasificaciones. De cara a este proyecto, sin embargo, diferenciaremos los métodos de clasificación de la siguiente manera; primero, por el grado de intervención humana, y después, por los diferentes métodos estadísticos/lógicos utilizados.

Si hablamos de grados de intervención humana, podemos dividir las técnicas de clasificación en 3 grupos:

2.3.1 CLASIFICACIÓN MANUAL

Hace referencia a la técnica que menos requiere de nuevas tecnologías o avances en machine learning. Es una técnica eficaz cuando el investigador sabe con certeza la zona a analizar y no tiene la intención de que el método se pueda extrapolar a otras situaciones. La fiabilidad de la clasificación depende de la capacidad del investigador de captar tonalidades, sombras, formas... para determinar las diferentes clases.

Este tipo de clasificación tiene tanto pros como contras. En primer lugar, como pros podríamos incluir la capacidad del cerebro humano de captar cosas que no se pueden calcular o cuantificar, es decir, en muchas ocasiones el cerebro humano es capaz de evidenciar ciertas ideas que una IA pasa por alto. Otro pro sería la posibilidad que nos ofrece el no necesitar un computador para realizar el análisis, técnicamente, una impresión de la imagen satelital debería ser suficiente para clasificarla de manera manual [12].

En cuanto a los contras, también podemos encontrar varios. Uno de ellos es que la precisión píxel a píxel que puede tener una IA es muy superior con respecto a la de un ser humano. Además, cuanto más específicas sean las clases, mejor será la clasificación hecha por una máquina con respecto a la hecha por un humano.

2.3.2 CLASIFICACIÓN HÍBRIDA

Tiene que ver en con la clasificación digital supervisada en el sentido de que esfuerzo humano y esfuerzo computarizado se unen para obtener una clasificación que, en algunos sentidos, es mejor que si solo se utilizara una técnica de las mencionadas anteriormente. La gran diferencia entre ambos es el grado en el que el operario interviene en la operación: en la clasificación supervisada, el operario define las directrices y no tiene más poder de intervención hasta que se obtiene el producto final. En un acercamiento híbrido a este problema, sin embargo, el factor humano es mucho más determinante. Este factor humano se puede observar de varias maneras.

Una de las formas de usar esta técnica híbrida de clasificación intenta utilizar las fortalezas de cada uno de los métodos de manera que también se reduzcan sus debilidades:

entre las fuerzas del factor humano contamos con la capacidad lógica de poder observar una imagen y saber qué es, pudiendo clasificarla por zonas sin mucha precisión, entre las ventajas de la máquina comentábamos antes su precisión, capaz de dividir una imagen en zonas de píxeles muy concretas basadas en las similitudes entre sus componentes. El método híbrido resultante se basa en utilizar la máquina para hacer esta precisa división de píxeles y en utilizar al humano para definir qué es cada familia de puntos, gracias a su mayor comprensión.

Otra de las maneras más utilizadas aprovecha esta idea, pero de una manera ligeramente diferente: la técnica comienza como una simple clasificación supervisada en la que la máquina clasifica una imagen basándose en las directrices introducidas en el programa por un usuario. Sin embargo, lo que la hace híbrida es la adición de un nuevo paso antes de dar por finalizada la clasificación. Este paso consiste en permitir que un operario compare la imagen original con la clasificación obtenida, en la mayoría de los casos superponiendo una sobre otra con un método normalmente llamado “swiping”, para poder marcar los errores e imprecisiones propios de la clasificación digital. Una vez marcados estos fallos, la utilización de otros tipos de software adicionales le permiten corregir la clasificación obtenida. Al finalizar el proceso, obtenemos un resultado más preciso[12].

2.3.3 CLASIFICACIÓN DIGITAL/NUMÉRICA

En esta técnica de clasificación se pretende aprovechar la gran capacidad de análisis de la computación para clasificar de manera eficiente un terreno cualquiera. Esta técnica entra en contraste con la mencionada anteriormente: en sus orígenes (años 70), la clasificación manual era la más precisa y, aunque la clasificación digital era capaz de manejar una mayor cantidad de información, la diferencia no era tan determinante. En la actualidad, sin embargo, la rapidez y precisión de la IA, junto con el poder de manipulación de ingentes cantidades de información, han colocado a la clasificación digital un gran paso por delante, como ha ocurrido en muchos otros ámbitos.

La clasificación digital, sin embargo, viene conducida por el ser humano y, como tal, puede ser influida por él. Dependiendo del nivel de esa influencia podemos obtener la clasificación supervisada, en la que un operario/investigador interviene ya sea definiendo

las clases a identificar o variando la sensibilidad del análisis. En el nivel no supervisado, el propio programa decide las directrices a seguir[13].

La gran precisión de este método radica en su capacidad de establecer modelos estadísticos/lógicos que determinan cómo de probable es que un píxel pertenezca a un grupo u otro. Estos modelos se han ido desarrollando a lo largo de los años, pero destacan los siguientes: LDA (Linear Discriminant Analysis), TREE (o árboles de decisión), K-NN (algoritmo K de los vecinos más próximos) y el RF (Random Forest).

2.3.3.1 TIPOS

Aunque es importante considerar todas las opciones, las técnicas de clasificación que vamos a analizar y comparar son las digitales/numéricas, puesto que son las más eficaces en la actualidad. En primer lugar, es importante hablar más en profundidad de los métodos estadísticos que han sido mencionados anteriormente puesto que es la manera en la que mejor se ejemplifica diferentes clasificaciones de píxeles.

Algo a destacar de este tipo de clasificaciones y que va a ser un tema recurrente a lo largo del proyecto es que son de tipo supervisado, es decir, la clasificación en sí se realiza de manera automática siguiendo una serie de directrices definidas por el algoritmo usado, pero la información inicial y el análisis del resultado final es realizado e interpretado por una persona.

2.3.3.1.1 LINEAR DISCRIMINANT ANALYSIS

Como primer método nos encontramos el LDA (Linear Discriminant Analysis). Su origen se da en los años 60 y tiene diferentes variables según su uso. Una de las primeras fue creada por Edward Altman, que en 1968 usó el método LDA para predecir la probabilidad de que una compañía entrara en bancarrota con un 80-90% de éxito mediante el uso de más de 30 años de datos.

El LDA destaca en la actualidad por su uso en campos como clasificación, reducción de dimensiones y visualización de información. No es el método más avanzado, pero resulta

atractivo si lo que buscas como resultado de una clasificación son unos datos decentes, sólidos e interpretables. De hecho, el LDA suele ser el primer método utilizado a la hora de intentar una clasificación, funcionando a modo de guía antes de implementar otros métodos más complejos y precisos[14].

La idea principal del LDA es encontrar la transformación óptima que permita una mejor separación de clases. Esta transformación o proyección se obtiene maximizando la dispersión entre clases al mismo tiempo que se minimiza la dispersión entre miembros de una misma clase, lo que permite obtener la discriminación entre clases. La función objetivo en un LDA clásico es un problema de densidad de probabilidad, en el que la proyección óptima puede ser computada por un autovalor general. Gracias a esta discriminación entre clases, la manera más aprovechable de utilización de LDA es para problemas de clasificación.

Matemáticamente hablando, en problemas de clasificación usamos el LDA como un método supervisado. Un ejemplo de funcionamiento es el siguiente: tenemos una variable z que puede formar parte de un número K de clases, teniendo la probabilidad de que sea perteneciente a una clase como la función $f(z)$. Teniendo en cuenta que el espacio se encuentra dividido en un número K de clases, la clasificación LDA se encarga de colocar z en la clase a si z se encuentra en la región a .

Cuando todas las clases tienen la misma probabilidad de incluir a z en su región, se determina que el LDA sigue la regla de la máxima probabilidad. En contraposición a esto, si conocemos las probabilidades previas de que z pertenezca a una clase en particular, se determina que el LDA sigue la regla bayesiana.

Desde su origen hace más de 50 años, el método LDA ha sufrido muchos cambios para mejorar su rendimiento en situaciones específicas. Como ejemplos de esto, podemos incluir el famoso PCA (Principal Component Analysis) o el menos conocido OLDA (Orthogonal Linear Discriminant Analysis). Se procederá a realizar una breve explicación de ellos para recalcar la polivalencia que tiene un método como el LDA.

La principal aplicación del PCA se encuentra en el campo del reconocimiento facial, muy desarrollado en los últimos años. El principal objetivo del PCA en este caso es la reducción del número de características utilizadas en el reconocimiento sin perder calidad en la clasificación final de los píxeles. El OLDA es un método menos conocido y, a

grandes rasgos, supone una mejora directa del método LDA. Se basa en la imposición de una ortogonalidad entre los vectores de proyección, lo que sumado a un procedimiento bien organizado de iteración, permite obtener un resultado generalmente más preciso, ya que este método busca reducir la información redundante [15].




Figure 2. Ejemplo de clasificación mediante métodos LDA y PCA

Como conclusión, entre las ventajas de uso del LDA podemos encontrar: facilidad de interpretar la información obtenida (el método de máxima probabilidad es simple de entender), robustez de los datos conseguidos y la capacidad de reducir la dimensión de los datos de la clasificación, haciendo más sencillo su manipulación y visualización. Entre sus inconvenientes podemos destacar los siguientes: limitaciones en cuanto a la precisión de los datos obtenidos, uso de un número de parámetros demasiado grande si el número de dimensiones iniciales es elevado (lo que ralentiza su uso) y, en general, la simplicidad del método, ya que es muy difícil obtener unos resultados verdaderamente óptimos con un sistema que carece de la complejidad adecuada [16].

2.3.3.1.2 TREE

El método TREE o DT (Decission Tree) lleva siendo utilizado desde su origen alrededor de 1960. Aunque no se sabe con seguridad quién fue el primer impulsor de este método

(hay argumentos que sitúan la creación del método en Gran Bretaña y otros que se lo adjudican a los matemáticos americanos Morgan y Sonquist), ya desde su inicio se observaba su polivalencia y utilidad en muchos ámbitos. De hecho, uno de los primeros usos de este método de los que se tiene constancia se trata de un estudio realizado por la Universidad Tecnológica de Poznan (Polonia) en el campo de la psicología, a partir del cual numerosos científicos descubrieron su potencial para el campo de la programación.

Así, al mismo tiempo que el ser humano empezaba a desarrollar campos relacionados con la computación, el método TREE avanzaba paralelamente a estos, comenzando a mostrar su utilidad en numerosos ámbitos como el modelado predictivo, la clasificación o machine learning. En los últimos años, además, versiones más avanzadas de este método se usan para manejo de datos, tanto como modo de entrenamiento como para data mining.

Como el LDA, el método TREE también es un método supervisado. Su funcionamiento comienza con un único nodo y una serie de datos que sirven como información inicial. Con estas características en mente, se aplican una serie de condiciones de manera jerárquica con el objetivo de llegar a una conclusión o nodo terminal. Estas condiciones, que se aplican de manera iterativa, van dividiendo el espacio en llamadas “hojas”. Tras cada división, se utiliza la información inicial junto con las condiciones impuestas para poder calcular la probabilidad del siguiente elemento[17].

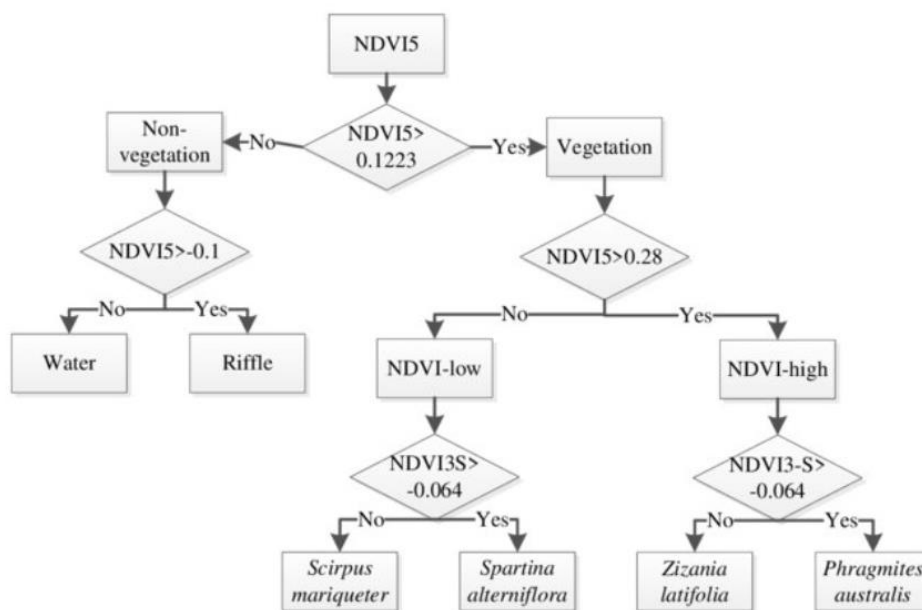


Figure 3. Ejemplo de clasificación mediante método TREE

De esta manera, es relativamente fácil obtener una clasificación que sea consistente con los datos iniciales dados: el verdadero reto llega cuando quieres construir un buen árbol de decisión. Esto suele significar construir el árbol más pequeño posible, en el que se da por hecho que las decisiones realizadas en cada nodo han sido las más eficientes para llegar al punto final.

La utilización de este método de predicción tiene muchas ventajas, entre las que se cuentan las siguientes: facilidad de interpretación y explicación a cualquier tipo de usuario (no todas la personas tienen una formación en ingeniería o matemáticas, por lo que es necesario considerar métodos intuitivos si se pretenden mostrar a gente con poco perfil técnico), ahorro de energía y tiempo por parte del usuario (muchos métodos actuales necesitan un tratamiento previo de la información a clasificar de cara a mejorar el rendimiento de la clasificación, el método TREE, sin embargo, no necesita este tratamiento previo ya que obtendrá el mismo resultado) y capacidad de poder tratar con parámetros con relaciones no lineales (muchos métodos de regresión actuales utilizan una relación linear entre los parámetros para realizar la clasificación, en el caso del método TREE, esto no es necesario, lo que permite una cierta flexibilidad a la hora de obtener estos datos).

El TREE es considerado actualmente el modelo de referencia en cuanto a modelos basados en particiones se refiere. Esto es debido, en gran parte, a la utilización de un método sólido que obtiene buenos resultados la mayoría de las ocasiones. Sin embargo, este método tiene algunas carencias muy bien definidas. En primer lugar, los DT con de gran tamaño o complejidad pueden llegar a una clasificación errónea o demasiado alejada del objetivo. Esto es debido a que una pequeña desviación por cada decisión provoca fallos cuando el número de decisiones llevadas a cabo son elevadas. Además, otro aspecto importante es la capacidad de crecimiento de un árbol de decisión. Al tener un número de ramas que crece de manera exponencial, cuando se enlazan un gran número de decisiones obtenemos un sistema muy ancho que, además de ser impreciso, ralentiza la clasificación. Para evitar esto es necesario establecer condiciones que limiten el crecimiento del árbol[18].

2.3.3.1.3 K-NN

El método k-NN (Nearest Neighbors) es un método no paramétrico de clasificación de datos que tiene su origen en un informe realizado por Evelyn Fix (1904-1965), matemática y profesora de Estadística en la Universidad de Berkeley, y Joseph Lawson Hodges Jr. (1922-2000), también un estadístico en Berkeley que además colaboraba con la USAF (United States Air Force). Lo más curioso de este informe, publicado en 1951, es que ni los propios Evelyn y Joseph sabían lo que estaban creando con el mismo. Un proyecto que comenzó como un análisis de medios no paramétricos de tratamiento de datos acabó siendo, años más tarde, el método k-NN, que actualmente se sitúa en los puestos más altos en cuanto a importancia y uso.

Durante toda la segunda mitad del siglo XX, estadísticos y matemáticos de todo el mundo estudiaban el k-NN y sus posibles funciones. Como el resto de los algoritmos tratados hasta ahora, sus principales funciones eran la clasificación y parametrización de un conjunto de datos. Sin embargo, en los últimos años se ha estudiado su potencial en un campo donde verdaderamente tiene ventaja frente a otros métodos: el campo computacional. Actualmente, versiones del k-NN se usan en sistemas de detección de malware, redes de comunicación... pero también en data mining y reconocimiento de patrones.

En cuanto a cómo funciona este método, solo hay que fijarse en su nombre. El clasificador k-NN juega con la distancia euclidiana que tienen entre sí los elementos objeto de clasificación. Primero, el algoritmo elige un elemento no clasificado y observa el número de elementos “k” más cercanos al mismo. Estos elementos están etiquetados según la clase a la que pertenecen. Así, el k-NN analiza a los vecinos del elemento a clasificar y extrae la clase única más repetida entre los mismos. Según este sistema, esta clase coincidirá con la clase del elemento siendo clasificado [19].

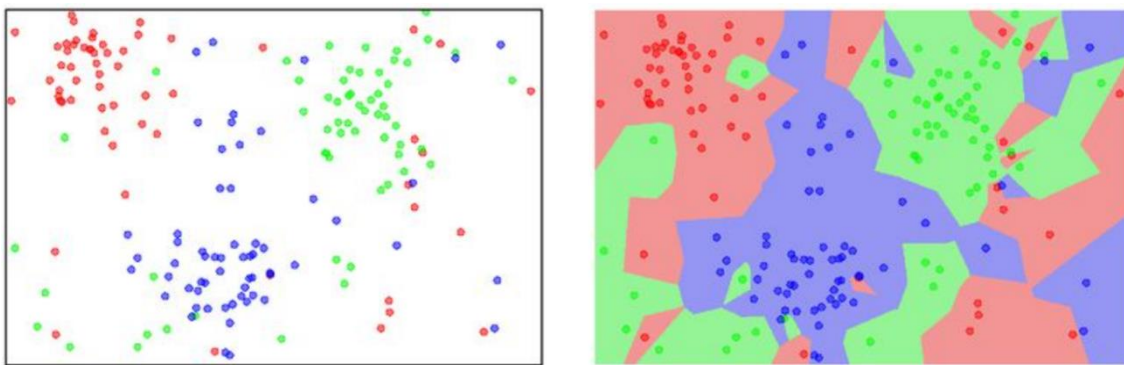


Figure 4. Ejemplo de clasificación mediante método K-NN

Como se puede observar, este no es un método muy complejo, pero según el objetivo que se esté buscando los resultados suelen ser satisfactorios. Además, hay una serie de variables que el usuario puede cambiar de manera muy simple, como alterar las distancias entre elementos o dar diferentes pesos a las clases de los vecinos, que pueden mejorar la clasificación notablemente.

En cuanto a mejoras, este algoritmo es de los más modificados a lo largo de los años debido a su gran potencial. Dos aspectos muy importantes han evolucionado de manera que el k-NN ahora es mucho más efectivo que cuando fue creado: la propia matemática que va detrás de este algoritmo y las máquinas utilizadas para realizar la clasificación. En cuanto a las modificaciones, podemos encontrar métodos tan conocidos como el Fk-NN (Fuzzy k-NN), elaborado por el matemático James Keller en 1985, o métodos más específicos como el Sk-NN (Semantic k-NN), creado con el objetivo de ser utilizado en el campo del machine learning.

El Fk-NN destaca por ser capaz de evitar algunos de los errores cometidos por el k-NN convencional. Esto se consigue añadiendo un parámetro de “fuzzificación”, que determina el peso de la distancia entre parámetros a la hora de determinar la clase a la que pertenece el elemento siendo clasificado[20]. El Sk-NN, sin embargo, tiene otro acercamiento al problema: elegir desde el principio los datos iniciales que son más determinantes. Este sistema está diseñado con una serie de filtros que definen qué categoría de parámetros tiene más importancia, por lo que se da por hecho que el estudio de los elementos vecinos será más fiable [21].

Dicho todo esto, es importante remarcar, como se ha ido haciendo con el resto de los métodos, cuáles son las desventajas más claras de usar este tipo de algoritmo. Estas son, entre otras, las siguientes: la precisión del resultado depende de la precisión de la información inicial, puede ser un método lento (incluso para una máquina) cuando hay un gran número de parámetros a tener en cuenta y requiere una gran memoria para poder almacenar toda la información, lo que hace el proceso más caro y más dependiente de la maquinaria disponible. Sin embargo, es necesario poner todo esto en perspectiva: aún con todos estos fallos, el k-NN no solo es ampliamente utilizado, sino que es una referencia para cualquier método de clasificación supervisado, lo que nos da una idea sobre su efectividad.

2.3.3.1.4 RANDOM FOREST

Aunque hay muchos más métodos, en este proyecto solo se cubrirá hasta este último: el algoritmo RF (Random Forest). Este método surge oficialmente en el año 2001 en un paper escrito por Leo Breiman, que, como los creadores del método k-NN, era estadístico en la Universidad de Berkeley. Aunque este se considere el origen oficial, ya en 1995 se empezaron a estudiar las posibilidades de un algoritmo parecido. Leo Breiman siguió estudiando este algoritmo hasta que en 2006 registró “Random Forest” como marca comercial junto con la matemática y estadística Adele Cutler [22].

Uno de los aspectos más importantes de este algoritmo es que reduce las limitaciones de la información inicial. Lo que quiero decir con esto es que el Random Forest, a diferencia de otros algoritmos tradicionales paramétricos, no necesita utilizar asunciones estrictas para poder formar una distribución. Así, este algoritmo es mucho más flexible cuando se utilizan grandes cantidades de datos.

Para poder explicar bien el funcionamiento de este método hay que recordar cómo funciona el árbol de decisión explicado anteriormente. Como resumen, un árbol de decisión funciona llegando a un punto donde, mediante una serie de condiciones impuestas, se debe obtener una respuesta que nos dirigirá a la siguiente cuestión y así sucesivamente. El Random Forest no es más que una agrupación de árboles de decisión,

por lo que se trata de un método conjunto. Si el método TREE fuese un árbol y las ramas fueran las decisiones, el Random Forest agruparía a todo el bosque [23].

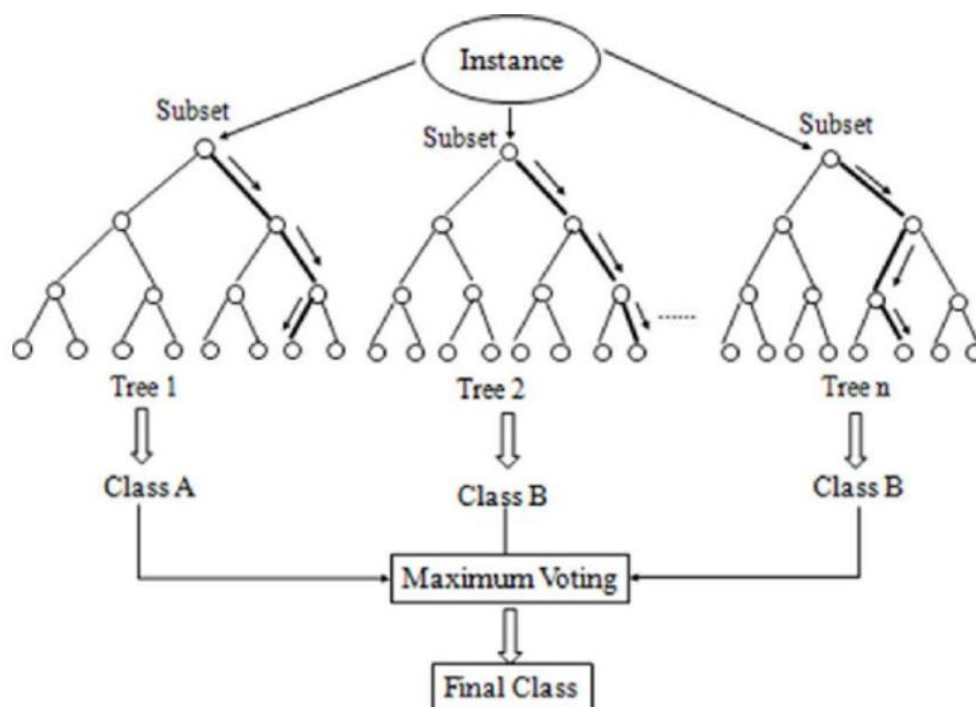


Figure 5. Esquema de clasificación mediante método Random Forest

Con este método, se podría llegar a pensar que van a surgir un gran número de problemas nuevos. Si el árbol de decisión tiene los problemas que se han analizado antes, sería razonable pensar que el RF va a tener los mismos problemas, pero multiplicados, puesto que se usan muchos árboles. Para desmentir esto, es necesario explicar algunas técnicas que van de la mano al RF y le permite ser un método generalmente más preciso y eficiente que el TREE convencional.

La primera técnica que se va a explicar es la agregación de Bootstrap, también conocida como empaquetado. El Bootstrap es un método de muestreo, en el que se escoge una muestra que es parte de un grupo mediante el método de reemplazo. El objetivo es obtener un grupo de predictores, por los que escogen muestras aleatoriamente para añadirlas al grupo Bootstrap mientras están siendo reemplazadas en su grupo original. En este punto se introduce la agregación. Mediante el método bootstrap hemos obtenido varios

predictores que serán los utilizados para ser combinados y obtener así una predicción final considerando todas las opciones posibles.

Otra técnica usada es la selección aleatoria de atributos (Random Subspace Method). Se basa en incrementar la diversidad entre miembros de la muestra provocando que diferentes clasificadores restrictivos actúen en subgrupos aleatorios del grupo original para obtener predictores determinados. Es similar al método de empaquetado, ya que ambos utilizan el método de reemplazo para seleccionar las muestras utilizadas para obtener el modelo predictivo [24].

A medida que mejoran nuestros medios computacionales van surgiendo más métodos agrupan a métodos anteriores. Entre estos podemos encontrar el método CERP (Classification by Ensembles from Random Partitions) que, a grandes rasgos, es un algoritmo que agrupa Random Forests.

Entre las ventajas de los Random Forests tenemos, por ejemplo, su gran precisión, la capacidad de utilizar y manipular un número elevado de variables de entrada y la habilidad de poder determinar qué variables son las más importantes a la hora de obtener la clasificación. En cuanto a las desventajas, podemos destacar la pérdida de la facilidad de interpretación con respecto a los árboles de decisión y el sobreajuste realizado sobre grupos de datos con clasificaciones ruidosas.

Table 3. Comparación entre tipos de clasificación digital supervisada

Tipos clasificación supervisada	Coste computacional	Manejo de gran cantidad de datos	Fácil interpretación de resultados	Fiabilidad
LDA	Medio	X	✓	Media-Baja
TREE	Alto	X	✓	Media-Alta
K-NN	Alto	X	✓	Alta
Random Forest	Medio	✓	X	Muy alta

2.4 SOFTWARES DE CLASIFICACIÓN

A la hora de decidir la herramienta a usar para realizar las clasificaciones, fue necesario un proceso de búsqueda extenso en el que se valoraron varias opciones. Sin embargo, no todas las opciones eran correctas, ya que para determinar la validez de la herramienta en

cuestión era necesario hacer un estudio sobre sus características y coste para confirmar que cumple con los objetivos de este proyecto.

2.4.1 LAND COVER CLASSIFIER

Se trata de un programa de código abierto diseñado por varios usuarios en la página GitHub. Está diseñado casi en su totalidad en código C# y la principal razón por la que fue sopesado en este proyecto es su coste, ya que se trata de un programa gratuito. Como se mencionó al inicio del proyecto, uno de los objetivos del mismo es conseguir clasificaciones precisas y accesibles a cualquier interesado, por tanto, el coste es un elemento importante.

Este programa, además, tiene herramientas muy interesantes como la de predicción, que utiliza la información de los píxeles conocidos para crear una imagen completamente nueva. Otra de las funciones de este programa es la de exportar a Unreal Engine 4. Unreal Engine 4 es un programa que te permite diseñar y crear objetos y terrenos de manera simulada en 3D y con gran realismo. Teóricamente, es programa te permitiría pasar de la imagen 2D obtenida con el satélite a una simulación 3D [25].

Sin embargo, el principal problema de este programa son los bugs. Cuando se comenzó el proyecto en GitHub mucha gente seguía su progreso y estaban dispuesto a ayudar con el código. En la actualidad, el código lleva sin haber sido retocado desde 2017, lo que lo hace inutilizable.

2.4.2 ENVI

ENVI es uno de los softwares de clasificación más avanzados del mercado. Está desarrollado por la empresa mexicana SIGSA, que tiene más de 30 años de experiencia en el sector. Han colaborado en proyectos militares, de desarrollo urbano, de seguridad pública, etc.

Además de las herramientas normales, también constan de otras funcionalidades entre las que destacan la realización de clasificaciones no supervisadas, la capacidad de realizar

análisis de subpíxeles y la detección de anomalías. Además, como fue mencionado antes, algunos satélites como el Sentinel-1 no tienen cámaras multiespectrales sino sistemas SAR. Una de las capacidades de este programa es poder usar la información obtenida de este tipo de sistemas [26].

Sin embargo, uno de los objetivos de este proyecto es que la clasificación de terreno sea accesible para cualquier persona y el precio de usar ENVI varía entre 700 y 1500 euros por año. Por lo tanto, si el coste económico no hubiera sido un factor determinante, este hubiera sido el software usado.

2.4.3 SEMI AUTOMATIC CLASSIFICATION PLUGIN

El Semi-Automatic Classification Plugin es un complemento de código abierto diseñado por Luca Congedo, un Ingeniero Medioambiental que actualmente forma parte del Instituto de Protección Medioambiental e Investigación (ISPRA) en Italia. El proyecto comenzó hace años y permite al usuario manipular datos obtenidos de varias misiones satelitales (Sentinel-1, Sentinel-2, Landsat...) para obtener clasificaciones y análisis de precisión supervisados [27].

Esta manipulación comprende la realización de varios tipos de clasificación entre los que se incluyen las posteriormente mencionadas, la realización de gráficos espectrales y de dispersión sobre bandas, el establecimiento de un número ilimitado de ROIs, etc.

Además, cumple los objetivos expresados anteriormente de accesibilidad (se trata de un software gratuito) y precisión por lo que, tras hacer un análisis de las opciones disponibles, se ha decidido utilizar el Semi Automatic Classification plugin para este proyecto.

Table 4. Comparación de softwares de clasificación

Tipos software clasificación	Precisión	Variedad de clasificaciones	Variedad de herramientas	Coste	¿Funcional?
LCC	Media	Baja	Media-Alta	Gratis	X
ENVI	Media-Alta	Media	Media	Gratis	✓
SAC	Alta	Alta	Alta	Muy alto	✓

3 DISEÑO DE LA SOLUCIÓN

En este apartado se definirá el proceso completo desde la definición de la necesidad hasta la valoración de resultados obtenidos en la clasificación, con el objetivo de mostrar de forma genérica cómo funciona un proceso de clasificación cualquiera. Por lo tanto, todos los puntos que se explicarán a continuación serán válidos sin importar el tipo de imagen elegida, el software usado o el algoritmo de clasificación seleccionado.

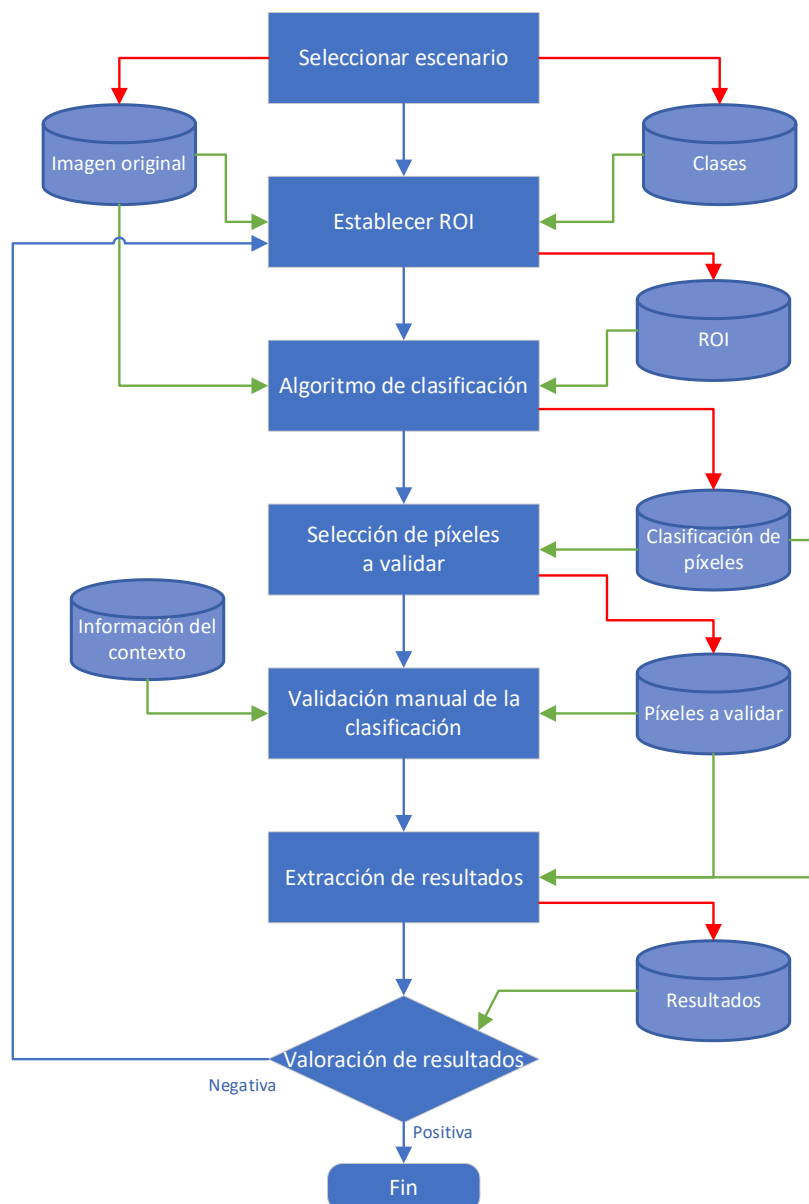


Figure 6. Esquema de la solución

Este diagrama es una representación gráfica que cumple 2 funciones: definir claramente el orden del proceso y mostrar cuáles son los productos y cuáles son las “materias primas” de cada proceso.

Así, el primer paso será seleccionar el escenario a clasificar, de lo que se obtendrán las clases definidas y la imagen satelital. Después se establecen los ROIs y se aplica el algoritmo de clasificación. Para el estudio de precisión primero se seleccionan los píxeles a validar (diseño de la muestra) y luego se hace una validación manual de los píxeles seleccionados. Por último, se extraen los resultados y con ellos se realiza una valoración subjetiva que concluirá con la decisión de que es válida (acabando el proceso) o no válida (volviendo al paso de establecimiento de ROIs para intentar mejorar la precisión total).

Un aspecto muy destacable de este tipo de clasificación, independientemente de la necesidad, objetivos o resultados, es que la precisión se calcula de una manera subjetiva. El usuario tiene el poder de decidir si una clasificación es válida o no apoyándose en los resultados numéricos que se han obtenido en el paso final del proceso. Además, toda esta clasificación es supervisada, es decir, el usuario se encarga tanto del establecimiento de ROIs y clases, pasando por la elección del algoritmo de clasificación utilizado y terminando por la validación manual y valoración de la clasificación.

3.1 SELECCIONAR ESCENARIO

La selección de escenario agrupa todos los pasos previos al establecimiento de ROIs. En este paso el usuario comenzará el proceso debido a una necesidad de obtener información sobre una imagen satelital, por lo que lo primero que se hará será elegir el terreno sobre el que se realizará la clasificación y los objetivos que se buscan con ella.

Con la selección de terreno es necesario tomar otras decisiones, como puede ser la elección del satélite del cual se extraerá la imagen satelital. Esta elección puede ser muy importante, ya que, como se mencionó en el apartado 2.1 INTRODUCCIÓN SATÉLITES, cada satélite obtiene imágenes de diferente resolución, diferente número de bandas, diferente tamaño... Una vez tomada la decisión, numerosas páginas web permiten la descarga de la imagen satelital deseada. En este paso se puede considerar el

uso de filtros para obtener una imagen más clara y precisa (porcentaje de nubes en la imagen, posición del satélite a la hora de tomar la imagen, etc.).

Los objetivos definirán las clases que se valorarán en la clasificación. Una clase en el contexto de clasificación de imágenes se puede definir como una agrupación de píxeles que tienen los mismos atributos de color entre ellos o parecidos (este parecido se define según el algoritmo de clasificación utilizado). Por ejemplo, un ejemplo de clase podría ser “Agua” que agruparía todos los píxeles de color azul de la imagen.

3.2 ESTABLECIMIENTO DE ROIS

Las regiones de interés (ROIs) son muestras de un tamaño específico de un grupo de datos que se usa como representación de dicho grupo a la hora de estudiarlos o usarlos para otros fines. En inglés también se conoce como “relevant measurement range” puesto que, hablando en términos literales, es el rango de una medida que se considera relevante con respecto a la totalidad de la misma [28].

Dependiendo de dónde se extraigan los datos y sus usos, obtendremos diferentes tipos de ROI que se diferencian por sus dimensiones de estudio [29].

- 1D: se suele tratar de un tiempo o un intervalo de frecuencia en una onda.
- 2D: se define mediante unos límites establecidos en una zona específica de una imagen.
- 3D: los límites actúan igual que los definidos en el 2D, con la diferencia de que dichos límites suelen rodear completamente un objeto. Este tipo de ROIs también se denominan VOIs, o volúmenes de interés.
- 4D: se trata de un VOI en un momento específico del tiempo.

Aplicado al diseño de la solución, en este paso se utilizará la imagen y clases definidas en el paso anterior para seleccionar los ROIs necesarios. Estos ROIs serán polígonos 2D que el usuario seleccionará en la imagen con el objetivo de determinar las propiedades de la clase según los atributos comunes de los píxeles seleccionados.

Siguiendo la línea de una clasificación supervisada, en ocasiones una primera selección de ROIs proporcionará un resultado poco óptimo (valoración subjetiva realizada por el

usuario) al final del proceso de ejecución de la solución. En estos casos es necesario seguir un proceso de prueba y error en el que se seleccionarán ROIs diferentes o se aumentará el número de los mismos con el objetivo de obtener una clasificación final más precisa.

3.3 ALGORITMO DE LA CLASIFICACIÓN

En este paso se usa la información obtenida por los ROIs establecidos en la imagen para realizar una clasificación de la misma. Un algoritmo de clasificación es un método de agrupación de píxeles en clases utilizando los atributos de unos píxeles de referencia y una base matemática específica.

En este paso se tiene que utilizar un algoritmo de clasificación supervisado, entre los que se encuentran los TIPOS de clasificación digital/numérica mencionados anteriormente. Hay métodos que son preferibles a otros según el objetivo, pero en la mayoría de las ocasiones lo mejor es elegir un método que sea generalmente robusto. En este proyecto es imposible incluir todos los métodos posibles, pero muchos de ellos tienen relación o comparten su base matemática con otros métodos que sí que han sido explicados, por lo que se incluyen más de los que puede parecer a primera vista.

Al aplicar el algoritmo de clasificación elegido se obtiene una imagen en la cual los píxeles se han dividido entre las diferentes clases definidas, obteniendo así una primera estimación del área que ocupa cada clase en la realidad.

3.4 DISEÑO DE LA MUESTRA

En este paso se seleccionan los píxeles a validar utilizando como herramienta las imágenes clasificadas del anterior apartado. Para poder realizar esta selección, es importante establecer el diseño de la muestra, que compila el conjunto de protocolos necesarios para seleccionar el grupo de píxeles que servirán como base al estudio de la precisión. Para elegir un diseño de la muestra válido es importante considerar los objetivos de la clasificación. Sin embargo, algo que está claro es que tiene que ser un

método de muestreo probabilístico, que a su vez deberá tener incorporado elementos aleatorios para la selección de muestras [30].

Los diseños de muestreo más usados que incluyen elementos aleatorios son el aleatorio simple, donde se seleccionan una serie de píxeles aleatorios en toda la imagen, y el aleatorio estratificado, donde se escogen una serie de píxeles aleatorios por clase. Para saber cuántos píxeles aleatorios por clase son los adecuados, se deben realizar una serie de cálculos estadísticos que tienen que ver con el porcentaje ocupado por esa clase en la imagen. Hay otros métodos (no probabilísticos) pero tienden más al error, como pueden ser: selección manual de los píxeles más convenientes, restringir la selección de píxeles a zonas homogéneas o utilizar un sistema ad hoc de selección de muestras, que suele derivar en una selección de píxeles dependiendo de la necesidad.

Sin embargo, aunque se consiguiera escoger el método perfecto en cada ocasión, siempre hay excepciones u obstáculos que evitan que la clasificación sea 100% precisa. Por ejemplo, en imágenes satelitales suele ocurrir que no todo el cuadrante esté compuesto por la zona a analizar o que esté parcialmente cubierto por nubes. Ambas desviaciones del estudio de precisión ideal deben ser cuantificadas y valoradas lo mejor posible para poder considerar el análisis válido. En muchas ocasiones, esta decisión es subjetiva y la responsabilidad recae sobre el realizador del estudio [30].

El muestreo aleatorio estratificado es un diseño práctico que satisface los objetivos básicos del estudio de precisión y la mayoría de los criterios de diseño. Entre sus ventajas podemos encontrar que este método de muestreo es capaz de aumentar el tamaño de la muestra en clases que ocupan un pequeño porcentaje de la imagen, lo que resulta en una reducción de los errores estándar específicos a este tipo de clases. Por lo tanto, este método cumple un objetivo clave: permite hacer un cálculo de la precisión por clase.

Además, el muestreo aleatorio estratificado es un diseño que ya ha demostrado su efectividad y que ha sido mejorado a lo largo del tiempo, lo que hace que expertos en la materia no solo lo acepten, sino que lo usen en algunos de sus estudios. Además, se ha desarrollado hasta el punto de poder ser utilizado con estimaciones de varianza objetivos, por lo que no será necesario el uso de estimaciones que puedan reducir la precisión del resultado final [30].

Por todas estas razones se ha elegido el muestreo aleatorio estratificado para realizar este estudio. Su funcionamiento es el siguiente: utilizando la información previa del porcentaje de la imagen ocupado por cada clase, se aplicarán una serie de fórmulas mediante las cuáles se obtienen el número de píxeles totales a clasificar y cuántos píxeles de cada clase serán clasificados. Una vez establecido esto, se procede al siguiente paso.

3.5 VALIDACIÓN DE LA CLASIFICACIÓN

En este paso se utilizan los píxeles aleatorios creados en el paso anterior y diferentes imágenes de referencia para poder clasificar los píxeles en sus clases reales. Para entender este paso es importante volver a remarcar que se trata de un proceso supervisado, por lo que la intervención del usuario en este paso será esencial.

En cuanto a las referencias mencionadas, se refieren a vídeos e imágenes de cualquier tipo que permitan clasificar los píxeles aleatorios creados en el anterior paso en su verdadera clase, y no en la clase asignada por el algoritmo de clasificación. En una situación ideal, todos los píxeles clasificados manualmente según las referencias coincidirían con la clasificación de clases asignadas por el algoritmo. Sin embargo, este nunca es el caso (al menos en imágenes que cubren un área amplia) por lo que esta clasificación de los píxeles tendrá una relación directa con los resultados obtenidos en apartados posteriores.

3.6 EXTRACCIÓN DE RESULTADOS

Una vez realizada la clasificación manual de los píxeles será necesario utilizar una de las herramientas que ofrecen los softwares de clasificación: los datos de la precisión. Estos datos son obtenidos por el programa tras cotejar las nuevas clases de los puntos clasificados manualmente con las clases asignadas a esos mismos puntos por el software de clasificación.

Los datos de precisión considerados en este estudio son 4: precisión de productor, precisión de usuario, precisión total y coeficiente kappa [31].

- Precisión de productor: representa los píxeles de una clase conocida que se clasifican como pertenecientes a otra clase. Se calcula dividiendo el número de píxeles correctamente clasificados de esa clase partido del número total de píxeles de esa clase obtenidos.
- Precisión de usuario: representa los píxeles que la clasificación ha determinado de una clase, pero a la hora de hacer la precisión usando la referencia se clasifican como otra diferente. Se calcula dividiendo el número de píxeles seleccionados como parte de una clase entre el número total de píxeles analizados de la misma clase.
- Precisión total: determina el porcentaje de píxeles clasificados correctamente.
- Coeficiente kappa: utiliza los valores globales obtenidos de precisión de productor y precisión de usuario para obtener un valor que describe la precisión global de la clasificación. Se encuentra entre 0 y 1.

La PA, UA y coeficiente kappa se extraen de la llamada matriz de confusión, donde se muestran todos los píxeles analizados y en qué clase se han clasificado. Además, si el valor de la PA o UA es bajo podemos dar por hecho la existencia de errores de precisión, que pueden ser de 2 tipos:

- Error de omisión: ocurre cuando un píxel no es clasificado en la clase que corresponde. Es complementario a la precisión de productor.
- Error de comisión: ocurre cuando un píxel es clasificado en una clase a la que no pertenece. Es complementario a la precisión de usuario.

3.7 VALORACIÓN DE RESULTADOS

Este es el último paso de la solución creada para este proyecto. En él se utilizan los valores obtenidos de PA, UA, PT y CK para poder evaluar de manera subjetiva si la clasificación realizada es válida o no. Para ello es necesario que el usuario tenga claro cuál era el objetivo de la clasificación en primer lugar, puesto que, en ocasiones, es más importante el valor de la precisión de una de las clases con respecto a la precisión global de la clasificación.

En toda clasificación hay que tener en cuenta que el error de la misma proviene de varias fuentes, que afectan al proceso en cada uno de los apartados de la solución diseñada. Entre los más reseñables podemos encontrar: utilización de una imagen poco definida o con baja resolución, elección errónea de clases o establecimiento inexacto de ROIs.

En esta parte de la clasificación no existe una guía que permita al usuario tomar la mejor decisión sobre la validez de la clasificación, será su trabajo el decidir si el resultado es aceptable.

Sin cambiar este último punto, es cierto que se pueden encontrar estudios en los que la precisión obtenida tiene un rango de valores amplios y en los que el usuario se puede basar para tomar decisiones con respecto a la validez del resultado. Sin ir más lejos, el estudio realizado en Argelia mencionado en la 1 INTRODUCCIÓN tiene un valor de la precisión del 69% [2], que puede ser un valor algo bajo si se aplica a otros campos.

4 EJECUCIÓN DE LA SOLUCIÓN

Para demostrar el correcto funcionamiento de la solución ideada en este proyecto, a continuación, se realizará todo el proceso con una serie de ejemplos que podrían tener aplicaciones en el mundo real. Hay que tener en cuenta en todo momento que estas clasificaciones se realizan porque no se pueden obtener en la actualidad los datos que se buscan (normalmente estimaciones del área ocupada por un cierto tipo de terreno), ya que, si se pudieran obtener de manera automática con otras herramientas, este estudio no sería necesario.

Para este proyecto es importante definir en primer lugar las herramientas que se utilizarán: las imágenes satelitales provienen del satélite Sentinel-2, el software de manipulación usado será QGIS y el software de clasificación será el Semi Automatic Classification Plugin.

4.1 SELECCIONAR ESCENARIO

Aplicando la solución explicada en el apartado de 3 DISEÑO DE LA SOLUCIÓN, los primeros pasos para realizar una clasificación completa son seleccionar los escenarios, elegir las clases y obtener las imágenes satelitales.

El estudio de las clasificaciones se va a realizar sobre 3 terreno específicos, y se ha establecido un objetivo/necesidad por el cual dichas clasificaciones tienen utilidad. Además, también se indican las clases que se utilizarán en posteriores apartados. Así, tras la realización completa del proceso diseñado en este proyecto podremos llegar a una conclusión sobre el objetivo definido.

Los tres casos con sus objetivos definidos se explican a continuación:

- Caso 1 (Madrid): como es la zona más conocida previa a la clasificación, se puede comenzar el análisis con una hipótesis de los resultados que se obtendrán, lo que permitirá, de manera cualitativa, realizar un cierto razonamiento sobre el sentido de los resultados obtenidos. Además, tiene zonas muy diferentes, lo que también permitirá separar con mayor efectividad los tipos de terreno.

Las clases por estudiar serán las siguientes: agua (para lagos, piscinas y ríos), edificios (para edificaciones y carreteras), zona boscosa (para prados y bosques) y tierra (para zonas sin vegetación o zonas de cultivo de cereal).

- Caso 2 (Córcega): a la hora de buscar otra zona en la que una clasificación puede ser obtenida, se pensó en un lugar que tuviera una clase grande y bien definida para comprobar cómo afectará a la precisión posterior.

El objetivo de esta clasificación no es otro que el análisis de la vegetación de la isla. El bosque en Córcega tiene 2 principales tipos de árboles: encinas (de un verde claro) y pinos (verde oscuro), por lo que, con esta clasificación, se procurará llegar a una conclusión sobre el área que ocupa cada especie.

En este caso, las clases a estudiar serán: agua (la clase dominante), zona boscosa clara (que incluye prados y cultivos), zona boscosa oscura (en contraste con la clase anterior), edificios (para edificaciones, puertos y carreteras) y tierra (para cultivos o zonas sin vegetación).

- Caso 3 (Dodge City): se trata de una ciudad en Arkansas que fue elegida en parte para demostrar que, en este tipo de estudios, no existen barreras en cuanto a lo que la distancia se refiere.

La principal razón de su elección es que, a su alrededor, se encuentran algunos de los campos de cultivo más interesantes observables a través de satélites. Las hectáreas que rodean la ciudad están plagadas de cultivos de diferentes tonalidades, marcando así el principal objetivo de esta clasificación; determinar el área que cubre cada tipo de cultivo: cultivo claro (trigo), cultivo ligeramente más oscuro (cebada) y cultivo oscuro (maíz). Además, la imagen elegida está cubierta en un cierto porcentaje con nubes, para poder estudiar cómo un agente externo puede afectar al estudio de precisión.

En este caso, las clases a considerar serán las siguientes: cultivo oscuro, cultivo claro, cultivo medio (con una intensidad de tono situado entre el cultivo oscuro y el claro), tierra (para zona sin vegetación), nube y sombras (para las sombras generadas por las nubes y para las zonas sin clasificar, pero con la misma tonalidad a los lados de la imagen).

En cuanto a la obtención de la imagen, se ha decidido obtener todas las bandas espectrales de las zonas a estudiar del satélite Sentinel-2. Esta decisión viene tomada por un gran número de ventajas:

- Resolución baja comparada con sus competidores (10m en comparación con los 60m del Landsat 8).
- Obtención de bandas espectrales que nos permite la manipulación de las mismas con el software QGIS (a diferencia del Sentinel-1, que utiliza un sistema SAR).
- Accesible y gratuito para todos (a diferencia de los satélites utilizados para realizar ciertos mapas como Google Maps).

Tomada esta decisión, es necesario obtener los datos que mejor convengan al estudio a realizar. Para ello, se utilizará la página web del programa Copernicus, que incluye todos los lanzamientos de satélites Sentinel. Este programa nos permite seleccionar una zona sobre la superficie terrestre para ofrecer todas las imágenes posibles que incluyan dicha zona.

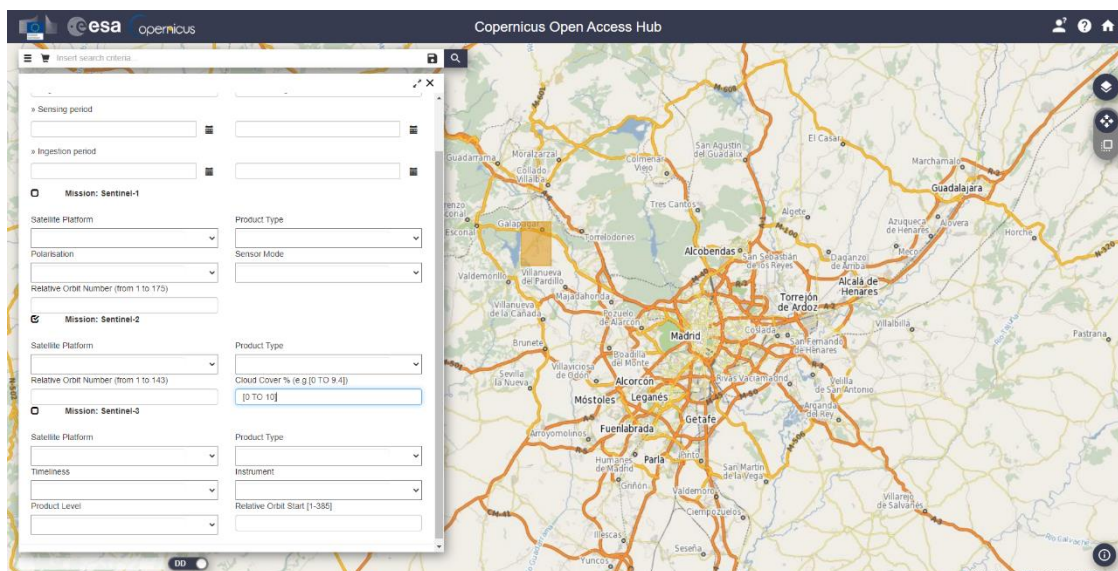


Figure 7. Opciones de filtros en la obtención de imágenes de las misiones Sentinel

Por lo tanto, se pueden obtener diferentes imágenes según el momento de tiempo si se quiere hacer un análisis temporal o si en un momento particular hay un obstáculo a la correcta visualización de la zona a estudiar, como pueden ser nubes u otros elementos

atmosféricos. A este respecto, el programa también nos permite utilizar una serie de filtros para elegir la imagen que más convenga: porcentaje de nubes, situación del satélite en su órbita terrestre, plataforma satelital desde la que se extrae la imagen (A o B), etc.

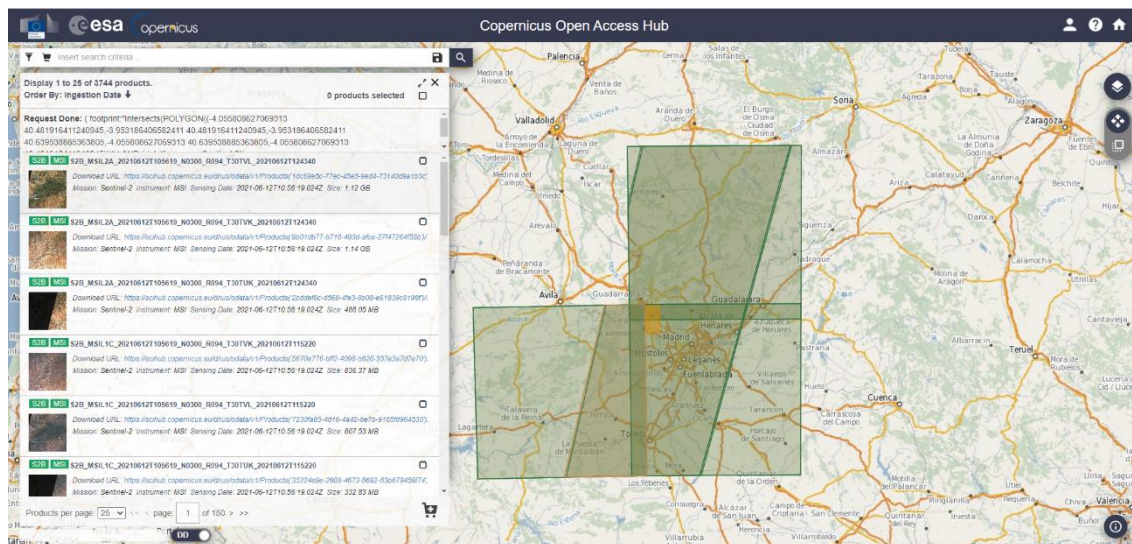


Figure 8. Visualización y descarga de imágenes Sentinel

Una vez visualizada y escogida la imagen, se procederá a su descarga. Esta descarga incluirá las 13 bandas espectrales que se utilizarán en los siguientes pasos y ocupa aproximadamente entre 4,5 y 5GB.

4.2 ESTABLECIMIENTO DE ROIS

Continuando el proceso de la solución propuesto, el siguiente paso consiste en el establecimiento de ROIs en cada una de las imágenes según las clases previamente definidas.

En este proyecto, los ROIs que son mencionados son los 2D, puesto que seleccionan un grupo de píxeles dentro de una imagen. Con la idea de que este grupo de píxeles formen una clase, los ROIs elegidos contienen píxeles con valores parecidos RGB.

Siguiendo las directrices mencionadas en el apartado 3.2 ESTABLECIMIENTO DE ROIS, los ROIs seleccionados definen las características de la clase sin interseccionar con otras.




Figure 9. Ejemplo de establecimiento de ROIs en el caso 3

4.3 ALGORITMO DE CLASIFICACIÓN

Este es el paso en el que se aplica un método de clasificación a la imagen con los ROIs definidos para poder clasificar los píxeles en clases. Como se ha mencionado antes, los métodos explicados en el apartado TIPOS no serán los aplicados en este caso, ya que el coste computacional de su aplicación es alto y no ofrecen una gran diferencia en cuanto a la precisión se refiere con respecto a otros métodos menos costosos. Por lo tanto, los métodos que aplicaremos serán los siguientes.

4.3.1 CLASIFICACIÓN POR ALGORITMO DE DISTANCIA MÍNIMA

La clasificación por mínima distancia es un método basado en la clasificación de un dato o grupo de datos en la clase que más se acerque a su distribución. Cómo de parecidos son muestra y clase se define como una distancia en el espacio de funciones de distribución. Comparte una parte de su base estadística con el método K-NN, explicado en el apartado 2.3.3.1.3 K-NN.

Este método se usa mucho en los campos de reconocimiento de patrones, como base en muchas clasificaciones de imágenes multi-espectrales. En general, la formulación de reconocimiento de patrones se formula a partir de espacios multidimensionales cuyo número de dimensiones depende de los vectores que lo conforman. En términos del vector, su dimensionalidad se verá afectada dependiendo del número de propiedades que se le atribuyan en una clasificación determinada, como podría ser el número de bandas espectrales a considerar. La diferencia entre clasificaciones píxel a píxel y vector a vector es que en la primera se clasifica cada píxel de manera individual, mientras que, en el caso de los vectores, estos son primero clasificados en grupos que más tarde serán asignados a una clase. Se podría hablar del método de mínima distancia como parte de este último grupo [32].

Al hablar de clasificaciones de imágenes, en muchas ocasiones los píxeles que rodean a un píxel elegido al azar suelen pertenecer a la misma clase. El problema ocurre en el momento en el que se quieren definir unos ciertos límites físicos para la agrupación de píxeles en una misma clase. En estos casos, es más común el uso de clusters, mediante los cuales se clasifican píxeles situados en diferentes puntos de la imagen al mismo tiempo y en la misma clase.

El principal problema de optimización del que se habla al explicar el algoritmo de mínima distancia es el establecimiento de la medida necesaria entre atributos de los elementos de la clasificación para conseguir la clasificación más precisa. En este sentido, se han propuesto muchas soluciones, como se puede observar en la siguiente tabla.

La clave de maximizar la precisión radica entonces en la elección de la distancia entre propiedades que mejor funcione con una clasificación particular. Esto, sin embargo, es casi imposible de determinar, por lo que se suelen adoptar ciertas fórmulas que tienen un alto porcentaje de acierto en la mayoría de los casos, como puede ser el método de la distancia Euclídea, cuyo cálculo se muestra a continuación [33].

$$d_{min} = \min_{s_i \neq s_j} |H(s_i - s_j)|^2$$

Donde H es una matriz compleja $M \times N$ y s_i es uno de los posibles vectores símbolo dentro de la matriz $N \times I$.

4.3.2 CLASIFICACIÓN POR ALGORITMO DE MÁXIMA PROBABILIDAD

El algoritmo de máxima probabilidad y el de mínima distancia son los más comunes a la hora de hacer análisis de imágenes satelitales. A grandes rasgos, el algoritmo de máxima probabilidad se trata de un método de clasificación supervisado que usa una serie de datos, llamados datos de entrenamiento, para poder operar. En este caso, los datos de entrenamiento serían los atributos de los píxeles que se encuentran dentro de los confines de los ROIs establecidos en el apartado anterior.

En este tipo de clasificaciones, es normal que los datos se encuentren en diferentes bandas del espacio espectral. Por lo tanto, es necesaria la utilización de una función de densidad de probabilidad por cada clase espectral, para lo cual se usa un modelo de probabilidad normal multivariante. Es importante destacar la función de las matrices de varianza y covarianza, que son las que determinan estas funciones de densidad [34].

Una vez realizados estos cálculos previos, solo falta la clasificación en sí. Usando estas funciones de densidad, se realiza una computación de la probabilidad del píxel de pertenecer a una de las clases disponibles. En este sentido, este método es una variante menos compleja del método 2.3.3.1.1 LINEAR DISCRIMINANT ANALYSIS.

Algunas de las razones por las que se elige este método son: la utilización de una base matemática bien documentada, el uso de datos estadísticos probados, la capacidad de asumir y clasificar datos covariantes... Por todo esto, es correcto aceptar que los resultados obtenidos por el método de máxima probabilidad van a ser generalmente robustos.

No se puede hablar de la estabilidad matemático-estadística del proceso sin explicar en profundidad el proceso. Este se basa en el teorema de Bayes que formula que la probabilidad de pertenencia ($P(i|\omega)$) de un píxel cualquiera con vector ω es [35]:

$$P(i|\omega) = \frac{P(\omega|i)P(i)}{P(\omega)}$$

Siendo $P(\omega|i)$ la función de probabilidad, $P(i)$ la probabilidad de que una clase i esté en el área a estudiar y $P(\omega)$ la probabilidad de obtener ω , que se determina como:

$$P(\omega) = \sum_{i=1}^M P(\omega|i)P(i)$$

Siendo M el número de clases. En conclusión, la asignación del píxel x a una clase i sigue la siguiente regla: $x \in i$ si $P(i|\omega) > P(j|\omega)$ para todo $j \neq i$.

4.3.3 CLASIFICACIÓN POR ALGORITMO DE ÁNGULO ESPECTRAL

La clasificación por algoritmo de ángulo espectral no es tan usada como las mencionadas anteriormente. Sin embargo, en este análisis se ha tenido en cuenta por su mejor actuación con respecto a otros algoritmos, al menos en los casos que se presentan en este proyecto.

Se trata de un algoritmo con base física que usa un espectro de referencia sobre el cual los píxeles son clasificados según un ángulo n-dimensional (dependiendo del n espacio de estudio). Así, tratando los píxeles como vectores n-dimensionales en el espacio, es posible calcular el ángulo entre espectros. Este método, a diferencia de otros, tiene la posibilidad de dejar píxeles sin clasificar, si el ángulo formado entre el píxel-vector es mayor que un cierto límite establecido previamente. Siguiendo este razonamiento, cuanto menor sea el ángulo formado, mayor será el parecido entre el píxel-vector y el espectro de referencia [36].

Para ilustrar esta explicación se ofrecerá un ejemplo simple de aplicación de este método. Si se tienen 2 bandas espectrales, un píxel-vector a y un espectro de referencia b, podríamos representar el ángulo espectral de la siguiente manera [37]:

$$\alpha = \cos^{-1} \left(\frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|} \right)$$




Figure 10. Esquema de clasificación de una muestra mediante ángulo espectral

Este método ha sido elegido, aparte de por conseguir resultados precisos, por su capacidad de clasificar terreno afectado por inconveniencias como brillos o sombras. Esto es debido a que el ángulo formado entre dos vectores es invariante, independientemente de su longitud.

4.4 CLASIFICACIÓN DE PÍXELES

El siguiente paso después de seleccionar los escenarios y establecer los ROIs es aplicar el algoritmo en el Semi Automatic Classification Plugin para obtener las imágenes de los terrenos ya clasificadas según el método aplicado (mínima distancia, máxima probabilidad y ángulo espectral).

Tras la realización de esta clasificación, es posible obtener los datos del área que ocupa cada una de las clases en la imagen, lo que es útil de cara a cumplir los objetivos de estimación de área. Sin embargo, tras la obtención de los datos de precisión, se obtiene otro valor del área, que es el área estimada de ocupación de cada clase teniendo en cuenta los resultados obtenidos en el análisis de los resultados. Estos 2 valores de área por cada una de las clases son los que vienen incluidos en las tablas situadas debajo de cada una de las imágenes. Cuando se obtenga un resultado, se determine el mejor método para

hacer una determinada clasificación y se quiera obtener una aproximación del área de la clase de estudio, se utilizarán los valores de área tras la precisión (columna derecha).

4.4.1 CASO 1




Figure 11. Imagen satelital de caso 1 (Madrid)

4.4.1.1 DISTANCIA MÍNIMA








Figure 12. Clasificación de caso 1 mediante distancia mínima

Table 5. Leyenda y área de la clasificación por distancia mínima (Caso 1)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Agua	3746,46	3278,1525
 Edificaciones	296558,17	216345,0155
 Vegetación	159392,51	242739,3575
 Tierra	745906,86	743241,4745

4.4.1.2 MÁXIMA PROBABILIDAD








Figure 13. Clasificación de caso 1 mediante máxima probabilidad

Table 6. Leyenda y área de la clasificación por máxima probabilidad (Caso 1)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Agua	378,32	29827,3369
 Edificaciones	353429,57	294510,8527
 Vegetación	86121,67	248096,4339
 Tierra	765674,44	633169,3764

4.4.1.3 ÁNGULO ESPECTRAL








Figure 14. Clasificación de caso 1 mediante ángulo espectral

Table 7. Leyenda y área de la clasificación por ángulo espectral (Caso 1)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Agua	378,32	29827,3369
 Edificaciones	353429,57	294510,8527
 Vegetación	86121,67	248096,4339
 Tierra	765674,44	633169,3764

4.4.2 CASO 2




Figure 15. Imagen satelital de caso 2 (Córcega)

4.4.2.1 DISTANCIA MÍNIMA









Figure 16. Clasificación de caso 2 mediante distancia mínima

Table 8. Leyenda y área de la clasificación por distancia mínima (Caso 2)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Bosque claro	231377,72	167218,3733
 Bosque oscuro	132204,76	151486,2367
 Agua	697332,24	697332,24
 Edificaciones	27990,24	58892,7086
 Tierra	116699,04	130674,4414

4.4.2.2 MÁXIMA PROBABILIDAD









Figure 17. Clasificación de caso 2 mediante máxima probabilidad

Table 9. Leyenda y área de la clasificación por máxima probabilidad (Caso 2)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Bosque claro	96487,32	82035,6601
 Bosque oscuro	82348,64	201891,8308
 Agua	696675,76	696675,76
 Edificaciones	46104,84	65498,0296
 Tierra	283987,44	159502,7196

4.4.2.3 ÁNGULO ESPECTRAL










Figure 18. Clasificación de caso 2 mediante ángulo espectral

Table 10. Leyenda y área de la clasificación por ángulo espectral (Caso 2)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 No clasificado	21538,28	21538,28
 Bosque claro	242509,28	165633,5619
 Bosque oscuro	115983,6	176610,92
 Agua	673397,32	673397,32
 Edificaciones	27724,96	73574,7524
 Tierra	124450,56	94849,1657

4.4.3 CASO 3




Figure 19. Imagen satelital de caso 3 (Dodge City)

4.4.3.1 DISTANCIA MÍNIMA










Figure 20. Clasificación de caso 3 mediante distancia mínima

Table 11. Leyenda y área de la clasificación por distancia mínima (Caso 3)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Cultivo oscuro	120088,32	175195,7109
 Cultivo claro	445093,68	261819,8118
 Cultivo medio	42500,32	122845,26
 Tierra	261335,6	331315,6204
 Nube	48525,8	48525,8
 Sombra	288060,28	265901,7969

4.4.3.2 MÁXIMA PROBABILIDAD










Figure 21. Clasificación de caso 3 mediante máxima probabilidad

Table 12. Leyenda y área de la clasificación por máxima probabilidad (Caso 3)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Cultivo oscuro	120088,32	175195,7109
 Cultivo claro	445093,68	261819,8118
 Cultivo medio	42500,32	122845,26
 Tierra	261335,6	331315,6204
 Nube	48525,8	48525,8
 Sombra	288060,28	265901,7969

4.4.3.3 ÁNGULO ESPECTRAL










Figure 22. Clasificación de caso 3 mediante ángulo espectral

Table 13. Leyenda y área de la clasificación por ángulo espectral (Caso 3)

Leyenda	Área inicial (km2)	Área tras precisión (km2)
 Cultivo oscuro	225985,72	225985,72
 Cultivo claro	121183,56	119309,6457
 Cultivo medio	341363,36	230119,791
 Tierra	81136,48	91165,5693
 Nube	345920,24	390359,762
 Sombra	67924,08	137618,232

4.5 DISEÑO DE LA MUESTRA

Ya en el apartado DISEÑO DE LA MUESTRA se explicaron las ventajas de un sistema de muestreo aleatoriamente estratificado, pero, para poder ser aplicado en este caso, harán falta una serie de cálculos.

En primer lugar, se necesitará establecer el número de muestras necesario para que el estudio de precisión sea significativo. Para ello será necesario tener primero la información del porcentaje que ocupa cada clase en la imagen. Después obtiene el valor que nos proporcionará el tamaño de la muestra usando la siguiente fórmula:

$$N = \left(\sum_{i=1} \left(\frac{W_i \cdot S_i}{S_0} \right) \right)^2$$

Donde N es el número total de muestras, W_i es el porcentaje mencionado anteriormente, S_i es la desviación estándar de la clase i (valor arbitrario dado por el usuario en el que su valor es mayor si W_i es menor, puesto que se da por hecho que las clases más pequeñas son las más precisas y viceversa) y S_0 es una medida de la desviación estándar del estudio de precisión, de valor igual a 0,01.

Sin embargo, el resultado de N puede ser un valor muy elevado, lo que haría el estudio de la precisión muy ineficiente debido a la cantidad de tiempo perdido en el mismo. Por ello, dentro del propio método se determina que este resultado se puede dividir entre 10 sin grandes cambios en la precisión final, pero con gran aumento en la rapidez del proceso, aunque siga siendo algo lento.

Una vez se tiene el número de muestras, es necesario determinar el número de ROIs que se crearán por clase. Para ello se utilizarán las siguientes fórmulas:

$$N_i = \frac{N}{c}$$

$$P_i = N \cdot W_i$$

$$M_i = \frac{N_i + P_i}{2}$$

Donde c es el número de clases y M_i es el número de muestras que se analizarán en cada clase.

A continuación, se mostrará unas tablas de ejemplo en las que se aplican las fórmulas explicadas previamente para obtener el tamaño de las muestras.

Table 14. Ejemplo de obtención de píxeles totales

LC Class	Wi	Si	Wi*Si
1	0.0035	0.5	0.00175
2	0.105	0.4	0.042
3	0.223	0.3	0.0669
4	0.669	0.2	0.1338
So=0.01			0.24445

Las columnas de esta tabla representan las clases (LC Class), el porcentaje de área que ocupa cada clase en la imagen (Wi), los valores del coeficiente de desviación estándar por clase (Si, siendo el valor inversamente proporcional al porcentaje de área ocupada por clase, pero sin superar el 0,5) y los valores obtenidos de multiplicar las 2 columnas anteriores (Wi*Si).

$$N = \left(\frac{0,24445}{0,01} \right)^2 = 597 \text{ muestras}$$

Esta fórmula utiliza la suma de los elementos de la última columna de la tabla anterior y lo divide por So (0,01). Al elevar todo al cuadrado se obtiene el número de muestras total. Al dividir entre 10 y aproximar se obtiene el número de muestras totales que se clasificarán en el paso de validación de la clasificación.

Table 15. Ejemplo de obtención de píxeles por clase

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	2	149	76	8
2	63	149	106	11
3	133	149	141	14
4	399	149	274	27
				60

Esta tabla tiene el objetivo de mostrar cuántos píxeles se validarán en cada clase. Las columnas de esta tabla representan el número de las clases (LC Class), el número de muestras asignadas a cada clase según su porcentaje de ocupación de la imagen (Wi*N),

el número de muestras totales entre el número de clases (Ptos Totales/Nº clases), la media de las 2 columnas anteriores (Media) y el número de píxeles que se validarán en cada clase (Nº muestras). Como se puede observar, la suma del número de píxeles obtenidos de cada clase nos da el número de píxeles totales a clasificar obtenidos con la fórmula anterior.

Explicado el cometido y contenido de las tablas de muestras, a continuación, se encuentran los cálculos hechos para cada una de las clasificaciones.

4.5.1 CASO 1

4.5.1.1 DISTANCIA MÍNIMA

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de distancia mínima en el caso 1.

Table 16. Obtención de píxeles a clasificar totales para caso 1 (Distancia mínima)

LC Class	Wi	Si	Wi*Si
1	0,0035	0,5	0,00175
2	0,105	0,4	0,042
3	0,223	0,3	0,0669
4	0,669	0,2	0,1338
So=0,01			0,24445

$$N = \left(\frac{0,24445}{0,01} \right)^2 = 597 \text{ muestras}$$

Table 17. Obtención de píxeles a clasificar por clases para caso 1 (Distancia mínima)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	2	149	76	8
2	63	149	106	11
3	133	149	141	14
4	399	149	274	27
				60

4.5.1.2 MÁXIMA PROBABILIDAD

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de máxima probabilidad en el caso 1.

Table 18. Obtención de píxeles a clasificar totales para caso 1 (Máxima probabilidad)

LC Class	Wi	Si	Wi*Si
1	0,00031	0,5	0,000155
2	0,293	0,3	0,0879
3	0,071	0,4	0,0284
4	0,635	0,2	0,127
So=0,01			0,243455

$$N = \left(\frac{0,243455}{0,01} \right)^2 = 593 \text{ muestras}$$

Table 19. Obtención de píxeles a clasificar por clases para caso 1 (Máxima probabilidad)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	1	148	74	7
2	174	148	161	16
3	42	148	95	10
4	377	148	263	26
				59

4.5.1.3 ÁNGULO ESPECTRAL

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de ángulo espectral en el caso 1.

Table 20. Obtención de píxeles a clasificar totales para caso 1 (Ángulo espectral)

LC Class	Wi	Si	Wi*Si
1	0,00154	0,5	0,00077
2	0,116	0,4	0,0464
3	0,159	0,3	0,0477
4	0,723	0,2	0,1446
So=0,01			0,23947

$$N = \left(\frac{0,23947}{0,01} \right)^2 = 573 \text{ muestras}$$

Table 21. Obtención de píxeles a clasificar por clases para caso 1 (Ángulo espectral)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	1	143	72	7
2	66	143	104	10
3	91	143	117	12
4	414	143	279	28
				57

4.5.2 CASO 2

4.5.2.1 DISTANCIA MÍNIMA

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de distancia mínima en el caso 2.

Table 22. Obtención de píxeles a clasificar totales para caso 2 (Distancia mínima)

LC Class	Wi	Si	Wi*Si
1	0,192	0,25	0,048
2	0,110	0,3	0,033
3	0,578	0,2	0,1156
4	0,0232	0,5	0,0116
5	0,0968	0,4	0,03872

$$N = \left(\frac{0,24692}{0,01} \right)^2 = 610 \text{ muestras}$$

Table 23. Obtención de píxeles a clasificar por clases para caso 2 (Distancia mínima)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	117	122	120	12
2	67	122	94	9
3	353	122	238	24
4	14	122	68	7
5	59	122	91	9
				61

4.5.2.2 MÁXIMA PROBABILIDAD

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de máxima probabilidad en el caso 2.

Table 24. Obtención de píxeles a clasificar totales para caso 2 (Máxima probabilidad)

LC Class	Wi	Si	Wi*Si
1	0,080	0,3	0,024
2	0,0683	0,4	0,02732
3	0,578	0,2	0,1156
4	0,0382	0,5	0,0191
5	0,236	0,25	0,059
So=0,01			0,24502

$$N = \left(\frac{0,24502}{0,01} \right)^2 = 600 \text{ muestras}$$

Table 25. Obtención de píxeles a clasificar por clases para caso 2 (Máxima probabilidad)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	48	120	85	9
2	41	120	81	8
3	347	120	234	23
4	23	120	72	7
5	142	120	131	13
				60

4.5.2.3 ÁNGULO ESPECTRAL

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de ángulo espectral en el caso 2.

Table 26. Obtención de píxeles a clasificar totales para caso 2 (Ángulo espectral)

LC Class	Wi	Si	Wi*Si
0	0,0179	0,25	0,004475
1	0,201	0,25	0,05025
2	0,096	0,4	0,0384
3	0,559	0,2	0,1118
4	0,023	0,5	0,0115
5	0,103	0,3	0,0309
So=0,01			0,247325

$$N = \left(\frac{0,247325}{0,01} \right)^2 = 612 \text{ muestras}$$

Table 27. Obtención de píxeles a clasificar por clases para caso 2 (Ángulo espectral)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	123	102	112	11
2	59	102	81	8
3	342	102	222	22
4	14	102	58	6
5	63	102	83	8
				55

4.5.3 CASO 3

4.5.3.1 DISTANCIA MÍNIMA

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de distancia mínima en el caso 3.

Table 28. Obtención de píxeles a clasificar totales para caso 3 (Distancia mínima)

LC Class	Wi	Si	Wi*Si
1	0,0996	0,3	0,02988
2	0,369	0,2	0,0738
3	0,0353	0,5	0,01765
4	0,217	0,25	0,05425
5	0,0403	0,4	0,01612
6	0,239	0,25	0,05975
So=0,01			0,25145

$$N = \left(\frac{0,25145}{0,01} \right)^2 = 632 \text{ muestras}$$

Table 29. Obtención de píxeles a clasificar por clases para caso 3 (Distancia mínima)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	63	105	84	8
2	233	105	169	17
3	22	105	64	6
4	137	105	121	12
5	25	105	65	7
6	151	105	128	13
				63

4.5.3.2 MÁXIMA PROBABILIDAD

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de máxima probabilidad en el caso 3.

Table 30. Obtención de píxeles a clasificar totales para caso 3 (Máxima probabilidad)

LC Class	Wi	Si	Wi*Si
1	0,115	0,3	0,0345
2	0,0631	0,4	0,02524
3	0,000179	0,5	0,0000895
4	0,518	0,2	0,1036
5	0,0995	0,3	0,02985
6	0,204	0,25	0,051
So=0,01			0,2442795

$$N = \left(\frac{0,2442795}{0,01} \right)^2 = 597 \text{ muestras}$$

Table 31. Obtención de píxeles a clasificar por clases para caso 3 (Máxima probabilidad)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	69	99	84	8
2	38	99	69	7
3	0	99	50	5
4	309	99	204	20
5	59	99	79	8
6	122	99	111	11
				59

4.5.3.3 ÁNGULO ESPECTRAL

Cálculo de píxeles totales y por clases que se validarán en la imagen correspondiente al algoritmo de clasificación de ángulo espectral en el caso 3.

Table 32. Obtención de píxeles a clasificar totales para caso 3 (Ángulo espectral)

LC Class	Wi	Si	Wi*Si
0	0,187	0,25	0,04675
1	0,101	0,3	0,0303
2	0,283	0,2	0,0566
3	0,0573	0,35	0,020055
4	0,287	0,2	0,0574
5	0,0563	0,4	0,02252
6	0,0183	0,5	0,00915
So=0,01			0,242775

$$N = \left(\frac{0,242775}{0,01} \right)^2 = 589 \text{ muestras}$$

Table 33. Obtención de píxeles a clasificar por clases para caso 3 (Ángulo espectral)

LC Class	Wi · N	Ptos Totales/Nº clases	Media	Nº muestras
1	59	84	57	6
2	167	84	126	13
3	34	84	59	6
4	169	84	127	13
5	33	84	59	6
6	11	84	48	5
				49

Con los datos sobre el número de píxeles a clasificar en cada uno de los casos se puede realizar la validación manual de la clasificación.

Es importante destacar que, antes de comenzar a realizar un análisis de precisión exhaustivo, es necesario dirigir un estudio básico de la clasificación de manera visual para detectar errores graves u obvios en el producto obtenido. Este estudio previo tiene 2 objetivos: en primer lugar, permite ver al usuario la idoneidad del mapa con respecto a su necesidad específica y también sirve para marcar errores que son fácilmente detectables, con la idea de corregirlos antes de continuar con el intenso estudio de precisión.

En este proyecto, es necesario crear primero los píxeles que se van a clasificar. La herramienta “Creación de ROI múltiples” del Semi Automatic Classification Plugin nos permite crear los píxeles aleatorios necesarios en cada una de las clases. Un ejemplo de píxel a clasificar se muestra en la siguiente imagen.




Figure 23. Ejemplo de píxel aleatorio para validación manual de la clasificación

Para poder asignar un píxel cualquiera a la clase a la que corresponde en la realidad es necesaria la utilización de referencias. En este proyecto se utilizan 3 referencias diferentes para poder asegurar la correcta clasificación de cada píxel lo máximo posible:

- La banda espectral 12 de la imagen satelital obtenida: cada una de las bandas de una imagen satelital aporta algo más de información a la imagen final. Sin embargo, hay bandas más completas que otras. La banda 12 permite observar la clase a la que pertenece el píxel en muchas ocasiones.
- Google Maps: esta herramienta permite ver casi todas las clases de un terreno cualquiera con bastante precisión. Sin embargo, tiene un problema por el cual solo se puede utilizar esta referencia para unos pocos píxeles que es que las imágenes que se obtienen de Google no corresponden al mismo momento de tiempo que la imagen satelital obtenida. Esto implica que puede haber zonas que hayan cambiado desde que se obtuvo la imagen para Google Maps, lo que provocaría que la clasificación de muchos de los píxeles fuera errónea.
- Open Street Maps: es un proyecto colaborativo de creación de mapas. Comenzó en 2004 en Gran Bretaña con el objetivo de aportar servicios cartográficos a cualquier persona de libre acceso, ya que la mayoría de los mapas utilizados en la actualidad son de propiedad privada y, en algunos lugares, es necesario adquirirlos. Así, voluntarios de todo el mundo están constantemente actualizando el mapa con nuevas zonas boscosas o urbanas, nuevas carreteras...

El problema de Open Street Maps es que tiene muy poca profundidad, por lo que solo ayuda en el caso de clasificaciones de píxeles en zonas con edificaciones, bosques (sin distinción entre vegetación) y zonas con agua.

Como se puede comprobar, ni con todas estas referencias es seguro que la validación manual sea 100% correcta. A parte de los problemas mencionados en cada una de las referencias, hay un problema añadido que se debe tener en cuenta a lo largo de todo el proceso: la resolución de la imagen. Las imágenes obtenidas con el satélite Sentinel-2 tienen una resolución de 10 m. Esto significa que cada píxel en la imagen representa un cuadrado de 10 m de lado en la actualidad. Por lo tanto, hay que tener en cuenta que la clasificación de píxeles que puedan pertenecer a varias clases queda a decisión del usuario, pudiendo variar la precisión si la decisión no es correcta.

4.7 EXTRACCIÓN Y VALORACIÓN DE RESULTADOS

Una vez realizada la validación de los píxeles de manera manual, el Semi Automatic Classification Plugin permite la utilización de una herramienta llamada “Precisión”. Esta herramienta crea en cada clasificación la llamada matriz de confusión, en la cual se muestran los píxeles clasificados por clases. De esta matriz se obtienen la precisión de productor, precisión de usuario, precisión total y coeficiente kappa. Es importante notar que, aunque en este apartado se usen solo los valores mencionados, las matrices de confusión y otros datos de precisión se encuentran en el ANEXO: MATRICES DE CONFUSIÓN.

A partir de estos datos, se ha decidido qué clasificaciones son válidas y cuáles no lo son, llegando a una serie de conclusiones sobre la fiabilidad y solidez de las mismas. Se ha decidido juntar la extracción y valoración de resultados para dejar más claro los razonamientos que llevan a declarar una clasificación no válida o válida.

4.7.1 CASO 1

4.7.1.1 OBJETIVOS

Como se ha mencionado anteriormente, el objetivo es poder analizar los valores obtenidos de los resultados del análisis de precisión teniendo en cuenta que la clasificación realizada es de una zona conocida, por lo que se pueden llegar a tener hipótesis sobre el resultado final.

4.7.1.2 DISTANCIA MÍNIMA

Table 34. Datos de precisión obtenidos para el caso 1 (Distancia mínima)

Precisión \ Clases	1	2	3	4
PA [%]	100	87,2305	65,6641	85,4907
UA [%]	87,5	63,6364	100	85,1852
PT [%]	81,8504			
CK	0,6687			

Esta clasificación no plantea ningún problema cuando se observa el resultado del análisis. Los mayores errores se encuentran entre las clases 2, 3 y 4 (edificaciones, vegetación y tierra) pero no son significativos. Además, estos errores tienen sentido puesto que estas zonas son las más difíciles de clasificar debido a las limitaciones a la hora de ver exactamente el color del píxel.

En general, se considera que es una clasificación válida puesto que los valores obtenidos de precisión total y coeficiente kappa son bastante altos también (PT>80% y CK>0,6).

4.7.1.3 MÁXIMA PROBABILIDAD

Table 35. Datos de precisión obtenidos para el caso 1 (Máxima probabilidad)

Precisión \ Clases	1	2	3	4
PA [%]	1,2684	60,0028	34,7130	79,0678
UA [%]	100	50	100	65,3846
PT [%]	63,3581			
CK	0,3684			

Este es el caso de una clasificación claramente no válida. Aunque los ROIs utilizados para cada clasificación son los mismos, diferentes métodos pueden variar en gran medida el resultado, como es el caso. En especial, los errores de omisión de la clase 1 no son

permisibles en una clasificación precisa, y el valor de PA y UA en las clases 2 y 3 es muy elevado también, lo que nos indica que seguramente los píxeles se hayan confundido entre estas 2 clases.

Para finalizar, los valores de PT y CK son muy bajos, lo que confirma lo comentado anteriormente sobre la falta de validez de esta clasificación.

4.7.1.4 ÁNGULO ESPECTRAL

Table 36. Datos de precisión obtenidos para el caso 1 (Ángulo espectral)

Precisión \ Clases	1	2	3	4
PA [%]	10,4016	64,0510	53,5768	94,4623
UA [%]	100	60	83,3333	82,1429
PT [%]	79,7893			
CK	0,5902			

Este caso es un poco especial, ya que la clasificación es bastante correcta, aún con valores muy bajos de PA en la clase 1. Esto nos indicaría que esta clasificación en específico no nos serviría para sacar conclusiones sobre todo el terreno, pero sí sobre las clases con mejores porcentajes, como en este caso es la 4. Esta sensación viene acentuada con los valores de PT y CK, que son muy elevados teniendo en cuenta todo lo anterior. Por tanto, esta clasificación sería parcialmente válida.

4.7.2 CASO 2

4.7.2.1 OBJETIVOS

En este caso el objetivo es demostrar un uso real que puede tener este tipo de clasificaciones: estudiar el área ocupada por diferentes tipos de vegetación. Por lo tanto, al finalizar con el análisis de la precisión podremos sacar una conclusión del área ocupada por especie vegetal.

4.7.2.2 DISTANCIA MÍNIMA

Table 37. Datos de precisión obtenidos para el caso 2 (Distancia mínima)

Precisión \ Clases	1	2	3	4
PA [%]	92,2457	87,2718	100	33,9482
UA [%]	66,6667	100	100	71,4286
PT [%]	88,6373			
CK	0,8148			

Este caso tiene poco que comentar. Cuanto más aumenta el número de clases, mayores son los errores de precisión, y más si las clases ocupan un área pequeña, como es el caso. Así, utilizaremos esta clasificación si necesitamos información sobre las clases de mayor área, puesto que, como se puede observar en los valores de PA y UA, tienen mayor precisión.

Como es esta la situación en la que nos encontramos, la clasificación es válida, puesto que además sus valores de PT y CK son muy elevados.

4.7.2.3 MÁXIMA PROBABILIDAD

Table 38. Datos de precisión obtenidos para el caso 2 (Máxima probabilidad)

Precisión \ Clases	1	2	3	4	5
PA [%]	65,3424	40,7885	100	50,2794	95,8707
UA [%]	55,5556	100	100	71,4286	53,8462
PT [%]	84,4786				
CK	0,7480				

Esta clasificación, en principio, es bastante precisa. Si se observan únicamente los valores de PT y CK se podría llegar a la conclusión de que es igual de válida que cualquier otra. Sin embargo, hay que tener en cuenta uno de los puntos que se querían analizar al realizar

la clasificación de una isla, y es ver cómo el tener una clase grande y precisa (3) podía afectar a la clasificación y aquí se puede observar justo eso, puesto que los valores de PA y UA de las clases en las que se tiene interés (1 y 2) es bajo (menor al 60% en 2 ocasiones).

Por tanto y teniendo el objetivo principal en mente, esta clasificación no sería válida.

4.7.2.4 ÁNGULO ESPECTRAL

Table 39. Datos de precisión obtenidos para el caso 2 (Ángulo espectral)

Clases Precisión	1	2	3	4	5
PA [%]	97,6088	65,6718	100	16,1497	87,4726
UA [%]	66,6667	100	100	42,8571	66,6667
PT [%]	86,7534				
CK	0,7920				

En este caso, es importante remarcar una situación que solo ocurre sobre este tipo de clasificaciones (ángulo espectral): algunos píxeles están sin clasificar. Como se explicó anteriormente, este método puede dejar píxeles sin clasificar, por lo que, cuando ocurre, se crea necesariamente una nueva clase que, aunque no afecta al estudio de precisión del resto de clases, sí que afecta al área ocupada.

Observando los valores de precisión, son aceptables en las clases que interesan al objetivo mencionado anteriormente (1 y 2), y los valores de PT y CK son muy elevados. Sin embargo, en este tipo de casos siempre conviene tener una visión de conjunto que te ayude a elegir la mejor opción. Como conclusión, esta clasificación sería válida teniendo en cuenta el objetivo, pero no sería elegida ante otra clasificación con mejores PA y UA del resto de clases (4 y 5).

4.7.3 CASO 3

4.7.3.1 OBJETIVO

El objetivo de esta clasificación no es otro que comprobar con qué método de clasificación se puede conseguir el valor de las áreas de cada tipo de cultivo más preciso. Por lo tanto, las clases a fijarse serán la 1, 2 y 3.

4.7.3.2 DISTANCIA MÍNIMA

Table 40. Datos de precisión obtenidos para el caso 3 (Distancia mínima)

Clases Precisión	1	2	3	4	5	6
PA [%]	59,9771	100	34,5966	52,5854	100	100
UA [%]	87,5	58,8235	100	66,6667	100	92,3077
PT [%]	74,4895					
CK	0,6762					

En esta clasificación se puede observar que, aunque los valores de PT y CK son muy elevados, los valores de PA y UA de las clases 1, 2 y 3 son algo preocupantes, alguno bajando del 50%. Esto ocurre porque, en la imagen, estas clases se funden unas con otras, por lo que es difícil clasificarlo por parte del programa, y analizarlo por parte del usuario. Algo a destacar, sin embargo, es el gran acierto en las clases 5 y 6, que actúan como interferencia al estudio de la imagen. Al tener este alto porcentaje de precisión, podemos concluir que esta clasificación será moderadamente válida para las clases 1, 2 y 3, pero también podremos asegurar que no tendrá ningún error muy grave, como el de asignar un píxel de la clase 1 a la clase 5 (nube).

4.7.3.3 MÁXIMA PROBABILIDAD

Table 41. Datos de precisión obtenidos para el caso 3 (Máxima probabilidad)

Clases Precisión	1	2	3	4	5	6
PA [%]	90,2638	21,7822	0,3436	91,3295	100	76,0290
UA [%]	100	57,1429	100	55	75	100
PT [%]	71,4923					
CK	0,6205					

Este caso sigue la línea de las otras clasificaciones analizadas mediante máxima probabilidad: es muy complicado clasificar diferentes clases en zonas pequeñas de la imagen. Como se puede observar, hay errores graves en los PA y UA de algunas clases, aunque la clasificación general sea sólida debido a sus altos valores de PT y CK. Por lo tanto, concluiremos que no servirá para el objetivo general, pero sí para hacerse una idea de la distribución cultivos-tierra-nubes y sombras.

4.7.3.4 ÁNGULO ESPECTRAL

Table 42. Datos de precisión obtenidos para el caso 3 (Ángulo espectral)

Clases Precisión	1	2	3	4	5	6
PA [%]	90,2850	89,0050	76,2849	77,5388	35,2549	100
UA [%]	88,8889	60	85,7143	87,5	71,4286	50
PT [%]	61,7388					
CK	0,5398					

Este caso es bastante singular. Como se puede observar, los valores de PA y UA de las clases 5 y 6 tienen algunos valores bajos, lo que significa que existirán errores graves, pero los porcentajes de las clases que se están monitorizando (1, 2 y 3) son bastante sólidos. Además, tenemos un bajo valor de PT, pero un valor de CK que, aunque bajo, es demasiado alto como para pertenecer a una clasificación que parece claramente

deficiente. Un aspecto a destacar otra vez es la existencia de un alto porcentaje de la imagen (casi un 20%) que forma parte del grupo de píxeles no clasificados.

Como conclusión, esta clasificación no serviría para obtener una imagen general del terreno, pero si se quiere obtener la mejor estimación del área de campos de cultivo, esta clasificación podría considerarse válida.

4.8 DISCUSIÓN DE RESULTADOS

Tras la realización del proceso diseñado en este TFG, se obtienen algunas conclusiones sobre los resultados y los algoritmos utilizados:

- El método generalmente más sólido es el método de mínima distancia, aunque haya casos específicos en los cuales otro clasificador sea ligeramente más preciso.
- Las clasificaciones de máxima probabilidad tienen muchos problemas cuando se encuentran con muchas clases que tienen los píxeles organizados en agrupaciones pequeñas. Además, la precisión de este método aumenta notablemente cuanto mayor sea el número de ROIs utilizados.
- El método de ángulo espectral es muy útil para clasificaciones con píxeles que se encuentran en agrupaciones pequeñas, pero la posibilidad de la existencia de píxeles sin clasificar es algo a tener en cuenta de cara a realizar el análisis de precisión.
- La obtención de áreas para un determinado fin utilizando estos estudios de precisión es posible, pero también es importante que el usuario lo interprete como una estimación y no como un dato exacto.
- La precisión de las clasificaciones aumenta notablemente cuanto mayor es la fiabilidad de la imagen de referencia, es decir, cuanto mayor sea la resolución de la imagen.
- En el caso 1, las hipótesis se cumplen y podemos observar que el porcentaje de cada clase se acerca a la realidad. El método elegido para este análisis es el de mínima distancia.
- El caso 2 es un ejemplo de cómo las clasificaciones se pueden ver afectadas con una clase dominante. Por ello, es recomendable realizar el estudio de precisión

sobre una imagen que no tenga este tipo de clases, para que las estimaciones sean más precisas. Dicho esto, el método elegido es el de mínima distancia, por lo que las áreas de vegetación estimadas son las de la tabla del apartado DISTANCIA MÍNIMA.

- El caso 3 acentúa los errores de algunos clasificadores mientras que potencia las ventajas de otros. Así, el método elegido para obtener las estimaciones objetivo es el de ángulo espectral, siendo las áreas de los campos de cultivo las aproximaciones obtenidas en la tabla ÁNGULO ESPECTRAL Sin embargo, se utilizaría el método de mínima distancia para obtener una imagen global del terreno.

5 PLANIFICACIÓN Y PRESUPUESTO

5.1 PLANIFICACIÓN

Para asegurar la realización de este Trabajo de Fin de Grado de manera correcta, se propone a continuación una estimación del tiempo dedicado a las diferentes tareas que componen el proyecto. Además, se añade también un diagrama de Gantt para poder visualizar la realización de estas tareas en el tiempo.

Se ha dividido este proyecto en las siguientes tareas:

- Aprendizaje (30 h): desde la elección del tema del Trabajo de Fin de Grado hasta el comienzo de su redacción, hubo un trabajo previo muy intenso de aproximación al tema.
- Búsqueda de información y redacción del estado del arte (30 h): aunque lo que destaca claramente en este proyecto es la parte práctica de clasificación del terreno, se debe dar una importancia considerable a la parte más teórica, puesto que es la que permite razonar sobre el proceso y los resultados obtenidos.
- Búsqueda de software (10 h): el objetivo era encontrar un software asequible para el usuario medio y capaz de manipular imágenes y realizar clasificaciones. Encontrar el software adecuado implicó la prueba e intento de adaptación de otros softwares menos adaptables.
- Obtención de imágenes y establecimiento de ROIs (25 h): este proyecto se probó con diferentes terrenos que se fueron descartando por no ser lo suficientemente representativos, que era uno de los objetivos principales. Además, optimizar la elección de los ROIs era un prueba y error que afectaba tremendamente al análisis final.
- Estudio de precisión (60 h): al ser una clasificación supervisada, la precisión se estudia según los datos aportados por el usuario. En este caso, para valorar diferentes terrenos, ROIs, métodos de clasificación... implicó la clasificación manual de cientos de píxeles que debían ser cotejados a su vez por mapas auxiliares, como se ha explicado en la memoria.

- Redacción de la memoria y revisión (80 h): incluye la redacción del resto de elementos de la memoria y la revisión ortográfica y de forma posterior.

ANÁLISIS DE CLASIFICACIÓN DEL TERRENO MEDIANTE IMAGEN SATELITAL

Este Trabajo de Fin de Grado comienza en noviembre de 2020, tras la elección de la temática y confirmación de la misma por parte de mi actual tutor. Su finalización se da el 24 de junio de 2021, siendo entregado tras 8 meses de trabajo. El proyecto, sin embargo, no se llevó a cabo de manera uniforme, como se puede ver en el siguiente diagrama:

Tarea / Mes	Noviembre	Diciembre	Enero	Febrero	Marzo	Abril	Mayo	Junio
Aprendizaje e introducción al tema								
Búsqueda de información y redacción del estado del arte								
Caso 1								
Caso 2								
Caso 3								
Redacción de la memoria y revisión								

Figure 24. Diagrama de Gantt del desarrollo del trabajo

5.2 PRESUPUESTO

En este apartado se mostrará un esquema con el coste económico que supone la redacción de este Trabajo de Fin de Grado. Es importante señalar uno de los objetivos que se han intentado cumplir a la hora de realizar este proyecto: que sea útil y de bajo coste.

En cuanto a los servicios y software empleado, son todos gratuitos. Hay servicios de obtención de imágenes por satélite de mayor calidad y capaces de enfocar una zona más concreta, pero era la intención de este proyecto demostrar que no es necesario la obtención de un material así para obtener resultados más que satisfactorios.

Por lo tanto, se puede llegar a la conclusión de que el grueso del coste económico vendrá de la mano de las horas dedicadas a este proyecto por parte del autor del trabajo, que figura como Graduado en Ingeniería Electrónica Industrial y Automática, y el tutor de este, en calidad de Doctor en Ingeniería de Software [38]. También habrá una parte de gastos variables (electricidad) y del precio del ordenador con las que se ha hecho este proyecto, que tiene unas especificaciones técnicas que permiten la correcta realización de este TFG.

Algo a destacar, sin embargo, es la existencia de un coste opcional para mejorar el rendimiento del trabajo. Todos los programas que se basan en el tratamiento de imágenes requieren un gran costo computacional, lo que se suele traducir en una velocidad de clasificación y análisis más lenta si se tiene un computador con capacidades limitadas. Por lo tanto, si durante el proyecto se hubiese decidido realizar un análisis de más terreno, muy posiblemente esto hubiera significado la necesidad de adquirir un ordenador de mayor potencia.

Table 43. Organización del presupuesto del proyecto

Descripción			Costes		
1	Personal	Doctor en Ingeniería	20 h	35,73 €/h	714,6 €
2		Graduado en Ingeniería	235 h	10,68€/h	2509,8€
3	Ordenador	8GB RAM			999 €
		Procesador Intel Core i5			
4	Costes variables	Electricidad	235 h	0,18 €/h	12 €
		QGIS			
5	Software	SAC Plugin	-	Gratuito	0 €
		Microsoft Office			
TOTAL					4235,4 €

6 CONCLUSIONES Y LINEAS DE INVESTIGACIÓN

6.1 CONCLUSIONES

Fijándose en los objetivos establecidos al inicio de este TFG y en los contenidos del mismo, podemos llegar a las siguientes conclusiones:

- Este TFG cumple las características de informe detallado en la temática de clasificación de terrenos. Se han explicado en profundidad softwares y métodos de clasificación.
- Las imágenes satelitales se han tratado de manera profunda, desde sus características hasta las de algunos de los principales satélites que obtienen este tipo de información.
- Este proyecto ha tenido especial cuidado en mostrar softwares de manipulación y diferentes tipos de análisis dentro del programa.
- En este TFG se han mostrado una gran cantidad de aplicaciones para las clasificaciones de imágenes por satélite. Además, en todo momento se ha tenido en cuenta el coste y la accesibilidad para realizar dichas clasificaciones.
- Se ha diseñado una solución que explica claramente y paso a paso todos los procesos necesarios para realizar una correcta clasificación.
- Se ha demostrado también como se realiza una valoración subjetiva de los resultados teniendo en cuenta los datos de la precisión. Además, en la discusión de resultados se deja claro que algoritmos son mejores según la situación.
- Este TFG tiene todas las partes necesarias que demuestran que el autor es un experto del tema tratado y que no sólo ha aprendido, sino que puede llegar a enseñar. Por lo tanto, se puede llegar a la conclusión de que este TFG demuestra que el autor tiene las capacidades necesarias para convertirse en Ingeniero.

6.2 LÍNEAS DE INVESTIGACIÓN

Es importante ser creativos con este tipo de métodos, puesto que no serlo sería desaprovechar su potencial. En la actualidad, el principal uso de ROIs y clasificación de píxeles se da en el campo de la medicina, para detectar anomalías en los resultados de escáneres o IRMs (imágenes por resonancia magnética). Este tipo de clasificaciones son mucho más precisas, ya que se utilizan aparatos con mucha más resolución y los métodos usados para la clasificación son los más precisos y complejos al tener a su disposición equipamiento al que no le afecta el elevado coste computacional.

Sin embargo, hay otro campo donde está comenzando a destacar el uso de clasificaciones mediante imágenes compuestas por muchas bandas espectrales: el control de calidad. En muchas ocasiones, los errores en un producto son muy complicados de detectar por operarios, por lo que en los últimos años se están utilizando imágenes hiperespectrales (compuestas por más de 200 bandas espectrales) para poder detectar los errores más pequeños y poder ofrecer al cliente los mejores productos.

Estos sistemas, sin embargo, utilizan métodos diferentes al utilizado en este proyecto. Las clasificaciones realizadas para control de calidad y en el ámbito de la medicina suelen ser procesos no supervisados, donde se tiene la información de lo que se quiere observar desde el principio, por lo que solo hace falta comparar las características de lo observado con las de la referencia para determinar si la detección es válida.

6.3 OPINIÓN PERSONAL

En este apartado se presenta una breve opinión personal sobre el potencial de este trabajo en la actualidad y el uso personal que le he dado.

En primer lugar, creo que está bastante claro que el principal enemigo de la utilidad de este proyecto es el desconocimiento. Se trata de un sector muy especializado, por lo que el 99% de las veces si se necesita cualquier tipo de información sobre un terreno se contratará a una empresa privada especializada, cuyos datos y herramientas superan a las de cualquier individuo. Sin embargo, aunque no creo que estas compañías pierdan su negocio al completo, sí que opino que el avance de la sociedad y la mejora en la utilización

de la tecnología por parte del usuario medio llevará a un futuro donde se confíe más en los resultados obtenidos de manera individual.

En segundo lugar, mi estudio de este tema ya me ha ayudado en mi vida personal, específicamente en mi trabajo. Actualmente me encuentro haciendo prácticas en el Departamento de Control de Producción de billetes en el Banco de España, y mi conocimiento de esta materia me ha llevado a la realización de un proyecto de aplicación de técnicas de clasificación para control de calidad de billetes. El objetivo del proyecto es la monitorización de billetes válidos y no válidos durante el proceso productivo, para ello se usan imágenes hiperespectrales y se aplica su consiguiente tratamiento de bandas para poder eliminar los billetes defectuosos en el momento de detección. El proyecto se encuentra en proceso de estudio, pero el potencial que tiene en el campo de reducción de perdido es de gran utilidad.

7 BIBLIOGRAFÍA

- [1] A. F. Carvajal y J. D. Pabón, «TRANSFORMACIÓN DE LA SUPERFICIE TERRESTRE POR LA ACTIVIDAD HUMANA Y SU RELACIÓN CON EL CAMBIO CLIMÁTICO», *Soc. Nat.*, vol. 28, pp. 185-198, ago. 2016, doi: 10.1590/1982-451320160201.
- [2] M. A. Tebbi y B. Haddad, «Improving infrared MSG satellite images classification, application on rainy areas detection», en *2016 8th International Conference on Modelling, Identification and Control (ICMIC)*, nov. 2016, pp. 747-750. doi: 10.1109/ICMIC.2016.7804211.
- [3] H. Ghrefat, A. Y. Kahal, K. Abdelrahman, H. J. Alfaifi, y S. Qaysi, «Utilization of multispectral landsat-8 remote sensing data for lithological mapping of southwestern Saudi Arabia», *J. King Saud Univ. - Sci.*, vol. 33, n.º 4, p. 101414, jun. 2021, doi: 10.1016/j.jksus.2021.101414.
- [4] «Sentinel-1 - Missions - Sentinel Online - Sentinel». <https://sentinels.copernicus.eu/web/sentinel/missions/sentinel-1> (accedido jun. 19, 2021).
- [5] J. Saha, Y. Khanna, J. Mukhopadhyay, y S. Aikat, «From Supervised to Unsupervised Learning for Land Cover Analysis of Sentinel-2 Multispectral Images», en *IGARSS 2020 - 2020 IEEE International Geoscience and Remote Sensing Symposium*, sep. 2020, pp. 1965-1968. doi: 10.1109/IGARSS39084.2020.9323985.
- [6] W. Zhou, «GIS for Earth Sciences», en *Encyclopedia of Geology (Second Edition)*, D. Alderton y S. A. Elias, Eds. Oxford: Academic Press, 2021, pp. 281-293. doi: 10.1016/B978-0-08-102908-4.00018-7.

- [7] J. Hofierka, M. Lacko, y S. Zubal, «Parallelization of interpolation, solar radiation and water flow simulation modules in GRASS GIS using OpenMP», *Comput. Geosci.*, vol. 107, pp. 20-27, oct. 2017, doi: 10.1016/j.cageo.2017.07.007.
- [8] «Productos - Portal gvSIG». <http://www.gvsig.com/es/productos> (accedido jun. 19, 2021).
- [9] X. Qiao, Z. Li, D. P. Ames, E. J. Nelson, y N. R. Swain, «Simplifying the deployment of OGC web processing services (WPS) for environmental modelling – Introducing Tethys WPS Server», *Environ. Model. Softw.*, vol. 115, pp. 38-50, may 2019, doi: 10.1016/j.envsoft.2019.01.021.
- [10] J. G. Moreno-Navarro, A. Medianero-Coza, y I. Hilal, «GIS modelling of intermodal networks: a comparison of two methods», València, Spain, jun. 2015, pp. 475-483. doi: 10.2495/UT150381.
- [11] «ArcGIS Online | Web GIS Mapping Software for Everyone». <https://www.esri.com/en-us/arcgis/products/arcgis-online/overview> (accedido jun. 18, 2021).
- [12] E. Alshari y B. Gawali, «Development of Classification System for LULC Using Remote Sensing and GIS», *Glob. Transit. Proc.*, vol. 2, ene. 2021, doi: 10.1016/j.gltp.2021.01.002.
- [13] J. Borràs, J. Delegido, A. Pezzola, M. Pereira-Sandoval, G. Morassi, y G. Camps-Valls, «Land use classification from Sentinel-2 imagery», *Rev. Teledetec.*, vol. 0, n.º 48, Art. n.º 48, jun. 2017, doi: 10.4995/raet.2017.7133.
- [14] «Linear Discriminant Analysis, Explained | by YANG Xiaozhou | Towards Data Science». <https://towardsdatascience.com/linear-discriminant-analysis-explained-f88be6c1e00b> (accedido jun. 16, 2021).

- [15] Q. Ye, N. Ye, y T. Yin, «Fast orthogonal linear discriminant analysis with application to image classification», *Neurocomputing*, vol. 158, pp. 216-224, jun. 2015, doi: 10.1016/j.neucom.2015.01.045.
- [16] L. Tan, «Chapter 17 - Code Comment Analysis for Improving Software Quality**This chapter contains figures, tables, and text copied from the author's PhD dissertation and the papers that the author of this chapter coauthored [[3], [1], [35], [7]]. Sections 17.2.3, 17.4.3, 17.5, and 17.6 are new, and the other sections are augmented, reorganized, and improved.», en *The Art and Science of Analyzing Software Data*, C. Bird, T. Menzies, y T. Zimmermann, Eds. Boston: Morgan Kaufmann, 2015, pp. 493-517. doi: 10.1016/B978-0-12-411519-4.00017-3.
- [17] V. Kotu y B. Deshpande, «Chapter 4 - Classification», en *Predictive Analytics and Data Mining*, V. Kotu y B. Deshpande, Eds. Boston: Morgan Kaufmann, 2015, pp. 63-163. doi: 10.1016/B978-0-12-801460-8.00004-5.
- [18] L. C. Leonard, «Chapter One - Web-Based Behavioral Modeling for Continuous User Authentication (CUA)», en *Advances in Computers*, vol. 105, A. M. Memon, Ed. Elsevier, 2017, pp. 1-44. doi: 10.1016/bs.adcom.2016.12.001.
- [19] A. Jain y R. L. Lella, «Pearson Correlation Coefficient Based Attribute Weighted k-NN for Air Pollution Prediction», en *2020 IEEE 17th India Council International Conference (INDICON)*, dic. 2020, pp. 1-8. doi: 10.1109/INDICON49873.2020.9342275.
- [20] A. Sengur, «Prediction of protein cellular localization sites using a hybrid method based on artificial immune system and fuzzy k-NN algorithm», *Digit. Signal Process.*, vol. 19, n.º 5, pp. 815-826, sep. 2009, doi: 10.1016/j.dsp.2009.03.012.
- [21] M. Ali, L. T. Jung, A.-H. Abdel-Aty, M. Y. Abubakar, M. Elhoseny, y I. Ali, «Semantic-k-NN algorithm: An enhanced version of traditional k-NN algorithm»,

- Expert Syst. Appl.*, vol. 151, p. 113374, ago. 2020, doi: 10.1016/j.eswa.2020.113374.
- [22] K. Pykes, «Random Forest Overview», *Medium*, mar. 14, 2020. <https://towardsdatascience.com/random-forest-overview-746e7983316> (accedido jun. 16, 2021).
- [23] R. M. Mohana, C. K. K. Reddy, P. R. Anisha, y B. V. R. Murthy, «Random forest algorithms for the classification of tree-based ensemble», *Mater. Today Proc.*, feb. 2021, doi: 10.1016/j.matpr.2021.01.788.
- [24] C. Sammut y G. I. Webb, Eds., «Random Subspace Method», en *Encyclopedia of Machine Learning and Data Mining*, Boston, MA: Springer US, 2017, pp. 1055-1055. doi: 10.1007/978-1-4899-7687-1_696.
- [25] B. Neukom, *bneukom/LCC.net*. 2021. Accedido: jun. 16, 2021. [En línea]. Disponible en: <https://github.com/bneukom/LCC.net>
- [26] «ENVI». <https://www.sigs.info/productos/envi> (accedido jun. 19, 2021).
- [27] L. Congedo, *semiautomaticgit/SemiAutomaticClassificationPlugin*. 2021. Accedido: jun. 19, 2021. [En línea]. Disponible en: <https://github.com/semiautomaticgit/SemiAutomaticClassificationPlugin>
- [28] «Region of Interest (ROI)», *SmartRay*. <https://www.smartray.com/glossary/region-of-interest-roi/> (accedido jun. 16, 2021).
- [29] D. Sánchez-Ruiz, I. Olmos-Pineda, y J. A. Olvera-López, «Automatic region of interest segmentation for breast thermogram image classification», *Pattern Recognit. Lett.*, vol. 135, pp. 72-81, jul. 2020, doi: 10.1016/j.patrec.2020.03.025.
- [30] P. Olofsson, G. M. Foody, M. Herold, S. V. Stehman, C. E. Woodcock, y M. A. Wulder, «Good practices for estimating area and assessing accuracy of land

- change», *Remote Sens. Environ.*, vol. 148, pp. 42-57, may 2014, doi: 10.1016/j.rse.2014.02.015.
- [31] T. Boca y G. Rodríguez, «Métodos estadísticos de la evaluación de la exactitud de productos derivados de sensores remotos», p. 24.
- [32] M. Pal, «Factors influencing the accuracy of remote sensing classifications: a comparative study», ene. 2002.
- [33] J.-H. Lee, «Minimum Euclidean distance evaluation using deep neural networks», *AEU - Int. J. Electron. Commun.*, vol. 112, p. 152964, dic. 2019, doi: 10.1016/j.aeue.2019.152964.
- [34] P. Bolstad y T. M. Lillesand, «Rapid maximum likelihood classification», *Photogramm. Eng. Remote Sens.*, vol. 57, pp. 67-74, ene. 1991.
- [35] A. Ahmad y S. Quegan, «Analysis of maximum likelihood classification on multispectral data», *Appl. Math. Sci.*, vol. 6, pp. 6425-6436, ene. 2012.
- [36] X. Liu y C. Yang, «A Kernel Spectral Angle Mapper algorithm for remote sensing image classification», en *2013 6th International Congress on Image and Signal Processing (CISP)*, dic. 2013, vol. 2, pp. 814-818. doi: 10.1109/CISP.2013.6745277.
- [37] B. Park, W. R. Windham, K. C. Lawrence, y D. P. Smith, «Contaminant Classification of Poultry Hyperspectral Imagery using a Spectral Angle Mapper Algorithm», *Biosyst. Eng.*, vol. 96, n.º 3, pp. 323-333, mar. 2007, doi: 10.1016/j.biosystemseng.2006.11.012.
- [38] «¿Cuánto Cobra un Ingeniero? (Sueldo 2021) | Jobted.es». <https://www.jobted.es/salario/ingeniero> (accedido jun. 20, 2021).

I. ANEXO DE SIGLAS

En este apartado se recopilan las siglas que han ido apareciendo a lo largo del documento.

Table 44. Tabla de siglas

Sigla	Término
<i>CERP</i>	Classification by Ensembles from Random Partitions
<i>CK</i>	Coeficiente kappa
<i>DEM</i>	Digital Elevation Model
<i>DT</i>	Decision Tree
<i>ESRI</i>	Environmental Systems Research Institute
<i>GIS</i>	Geographic Information System
<i>GRASS</i>	Geographic Resources Analysis Support System
<i>GUI</i>	Graphical User Interface
<i>GvSIG</i>	Generalitat Valenciana Sistema d'Informació Geogràfica
<i>IRM</i>	Imagen por Resonancia Magnética
<i>K-NN</i>	K- Nearest Neighbors
<i>LCC</i>	Land Cover Classifier
<i>LDA</i>	Linear Discriminant Analysis
<i>MPI</i>	Message-Passing Interface
<i>MSI</i>	Multi-Spectral Instrument
<i>NIR</i>	Near Infrared
<i>OGC</i>	Open Geospatial Consortium
<i>OLDA</i>	Orthogonal Linear Discriminant Analysis
<i>OLI</i>	Operational Land Imager
<i>OSGEO</i>	Open Source Geospatial foundation
<i>OSM</i>	Open Street Maps
<i>PA</i>	Productor's Accuracy
<i>PCA</i>	Principal Component Analysis
<i>POSIX</i>	Portable Operating System Interface
<i>PT</i>	Precisión Total
<i>QGIS</i>	Quantum Geographic Information System
<i>QUAC</i>	Quick Atmospheric Correction
<i>RGB</i>	Red Green Blue

Sigla	Término
<i>RF</i>	Random Forest
<i>ROI</i>	Region Of Interest
<i>SAC</i>	Semi Automatic Classification
<i>SAR</i>	Synthetic Aperture Radar
<i>SWIR</i>	Short-Wave Infrared
<i>TIRS</i>	Thermal Infrared Sensor
<i>UA</i>	User´s Accuracy
<i>VNIR</i>	Visible Near Infrared
<i>WMS</i>	Web Map Services

I. ANEXO: MATRICES DE CONFUSIÓN

En este apartado se ofrece toda la información de cada estudio de precisión, incluyendo las matrices de error y las de confusión.

I.I. CASO 1

I.I.I. DISTANCIA MÍNIMA

ErrMatrixCode	Referencia	Classified	PixelSum				
5	1	1	7.0				
10	2	2	7.0				
12	2	4	1.0				
13	3	1	1.0				
15	3	3	14.0				
16	3	4	3.0				
18	4	2	4.0				
20	4	4	23.0				
> ERROR MATRIX (pixel count)							
> Referencia							
V_Classified	0	1	2	3	4	Total	
0	0	0	0	0	0	0	
1	0	7	0	1	0	8	
2	0	0	7	0	4	11	
3	0	0	0	14	0	14	
4	0	0	1	3	23	27	
Total	0	7	8	18	27	60	
> AREA BASED ERROR MATRIX							
> Referencia							
V_Classified	0	1	2	3	4	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.0027	0.0000	0.0004	0.0000	37464600.0000	0.0031
2	0.0000	0.0000	0.1565	0.0000	0.0894	2965581700.0000	0.2460
3	0.0000	0.0000	0.0000	0.1322	0.0000	1593925100.0000	0.1322
4	0.0000	0.0000	0.0229	0.0687	0.5270	7459068600.0000	0.6187
Total	0.0000	0.0027	0.1794	0.2013	0.6165	12056040000.0000	
Area	0	32781525	2163450155	2427393575	7432414745	12056040000	
SE	0.0000	0.0004	0.0439	0.0381	0.0571		
SE area	0	4683075	528993118	459751276	688164647		
95% CI area	0	9178827	1036826510	901112501	1348802707		
PA [%]	nan	100.0000	87.2305	65.6641	85.4907		
UA [%]	nan	87.5000	63.6364	100.0000	85.1852		
Kappa hat	nan	0.8747	0.5568	1.0000	0.6137		
Precisión total [%] =81.8504							
Clasificación Kappa =0.6687							
Area unit = metre^2							
SE = standard error							
CI = confidence interval							
PA = producer's accuracy							
UA = user's accuracy							

Figure 25. Matriz de confusión de caso 1 (Distancia mínima)

I.I.I. MÁXIMA PROBABILIDAD

ErrMatrixCode	Referencia	Classified	PixelSum				
5	1	1	7.0				
8	1	4	1.0				
10	2	2	8.0				
12	2	4	4.0				
14	3	2	2.0				
15	3	3	10.0				
16	3	4	4.0				
18	4	2	6.0				
20	4	4	17.0				
> ERROR MATRIX (pixel count)							
> Referencia							
V_Classified	0	1	2	3	4	Total	
0	0	0	0	0	0	0	
1	0	7	0	0	0	7	
2	0	0	8	2	6	16	
3	0	0	0	10	0	10	
4	0	1	4	4	17	26	
Total	0	8	12	16	23	59	
> AREA BASED ERROR MATRIX							
> Referencia							
V_Classified	0	1	2	3	4	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.0003	0.0000	0.0000	0.0000	3783200.0000	0.0003
2	0.0000	0.0000	0.1466	0.0366	0.1099	3534295700.0000	0.2932
3	0.0000	0.0000	0.0000	0.0714	0.0000	861216700.0000	0.0714
4	0.0000	0.0244	0.0977	0.0977	0.4153	7656744400.0000	0.6351
Total	0.0000	0.0247	0.2443	0.2058	0.5252	12056040000.0000	
Area	0	298273369	2945108527	2480964339	6331693764	12056040000	
SE	0.0000	0.0244	0.0594	0.0522	0.0707		
SE area	0	294490169	716559511	629565009	852014914		
95% CI area	0	577200732	1404456642	1233947419	1669949232		
PA [%]	nan	1.2684	60.0028	34.7130	79.0678		
UA [%]	nan	100.0000	50.0000	100.0000	65.3846		
Kappa hat	nan	1.0000	0.3384	1.0000	0.2710		
Precisión total [%] =63.3581							
Clasificación Kappa =0.3684							
Area unit = metre^2							
SE = standard error							
CI = confidence interval							
PA = producer's accuracy							
UA = user's accuracy							

Figure 26. Matriz de confusión de caso 1 (Máxima probabilidad)

I.I.II. ÁNGULO ESPECTRAL

ErrMatrixCode	Referencia	Classified	PixelSum				
5	1	1	7.0				
7	1	3	1.0				
10	2	2	6.0				
11	2	3	1.0				
12	2	4	1.0				
14	3	2	1.0				
15	3	3	10.0				
16	3	4	4.0				
18	4	2	3.0				
20	4	4	23.0				
> ERROR MATRIX (pixel count)							
> Referencia							
V_Classified	0	1	2	3	4	Total	
0	0	0	0	0	0	0	
1	0	7	0	0	0	7	
2	0	0	6	1	3	10	
3	0	1	1	10	0	12	
4	0	0	1	4	23	28	
Total	0	8	8	15	26	57	
> AREA BASED ERROR MATRIX							
> Referencia							
V_Classified	0	1	2	3	4	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.0015	0.0000	0.0000	0.0000	18563500.0000	0.0015
2	0.0000	0.0000	0.0697	0.0116	0.0348	1399542300.0000	0.1161
3	0.0000	0.0133	0.0133	0.1326	0.0000	1918853800.0000	0.1592
4	0.0000	0.0000	0.0258	0.1033	0.5941	8719080400.0000	0.7232
Total	0.0000	0.0148	0.1087	0.2476	0.6289	12056040000.0000	
Area	0	178467983	1311025592	2984581978	7581964447	12056040000	
SE	0.0000	0.0133	0.0347	0.0532	0.0562		
SE area	0	159904483	418054112	640975589	677283031		
95% CI area	0	313412787	819386060	1256312154	1327474741		
PA [%]	nan	10.4016	64.0510	53.5768	94.4623		
UA [%]	nan	100.0000	60.0000	83.3333	82.1429		
Kappa hat	nan	1.0000	0.5512	0.7785	0.5188		
Precisión total [%] =79.7893							
Clasificación Kappa =0.5902							
Area unit = metre^2							
SE = standard error							
CI = confidence interval							
PA = producer's accuracy							
UA = user's accuracy							

Figure 27. Matriz de confusión de caso 1 (Ángulo espectral)

I.II. CASO 2

I.II.I. DISTANCIA MÍNIMA

ErrMatrixCode	Referencia	Classified	PixelSum					
6	1	1	8.0					
10	1	5	1.0					
11	2	1	1.0					
12	2	2	9.0					
18	3	3	24.0					
24	4	4	5.0					
25	4	5	3.0					
26	5	1	3.0					
29	5	4	2.0					
30	5	5	5.0					
> ERROR MATRIX (pixel count)								
> Referencia								
V_Classified	0	1	2	3	4	5	Total	
0	0	0	0	0	0	0	0	
1	0	8	1	0	0	3	12	
2	0	0	9	0	0	0	9	
3	0	0	0	24	0	0	24	
4	0	0	0	0	5	2	7	
5	0	1	0	0	3	5	9	
Total	0	9	10	24	8	10	61	
> AREA BASED ERROR MATRIX								
> Referencia								
V_Classified	0	1	2	3	4	5	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.1279	0.0160	0.0000	0.0000	0.0480	2313777200.0000	0.1919
2	0.0000	0.0000	0.1097	0.0000	0.0000	0.0000	1322047600.0000	0.1097
3	0.0000	0.0000	0.0000	0.5784	0.0000	0.0000	6973322400.0000	0.5784
4	0.0000	0.0000	0.0000	0.0000	0.0166	0.0066	279902400.0000	0.0232
5	0.0000	0.0108	0.0000	0.0000	0.0323	0.0538	1166990400.0000	0.0968
Total	0.0000	0.1387	0.1257	0.5784	0.0488	0.1084	12056040000.0000	
Area	0	1672183733	1514862367	6973322400	588927086	1306744414	12056040000	
SE	0.0000	0.0293	0.0160	0.0000	0.0167	0.0306		
SE area	0	353505297	192814767	0	201232293	368716253		
95% CI area	0	692870381	377916943	0	394415293	722683856		
PA [%]	nan	92.2457	87.2718	100.0000	33.9482	49.6140		
UA [%]	nan	66.6667	100.0000	100.0000	71.4286	55.5556		
Kappa hat	nan	0.6130	1.0000	1.0000	0.6996	0.5015		
Precisión total [%] =88.6373								
Clasificación Kappa =0.8148								
Area unit = metre^2								
SE = standard error								
CI = confidence interval								
PA = producer's accuracy								
UA = user's accuracy								

Figure 28. Matriz de confusión de caso 2 (Distancia mínima)

I.II.II. MÁXIMA PROBABILIDAD

ErrMatrixCode	Referencia	Classified	PixelSum					
6	1	1	5.0					
9	1	4	1.0					
10	1	5	1.0					
11	2	1	3.0					
12	2	2	8.0					
15	2	5	4.0					
18	3	3	23.0					
21	4	1	1.0					
24	4	4	5.0					
25	4	5	1.0					
29	5	4	1.0					
30	5	5	7.0					
> ERROR MATRIX (pixel count)								
> Referencia								
V_Classified	0	1	2	3	4	5	Total	
0	0	0	0	0	0	0	0	
1	0	5	3	0	1	0	9	
2	0	0	8	0	0	0	8	
3	0	0	0	23	0	0	23	
4	0	1	0	0	5	1	7	
5	0	1	4	0	1	7	13	
Total	0	7	15	23	7	8	60	
> AREA BASED ERROR MATRIX								
> Referencia								
V_Classified	0	1	2	3	4	5	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.0445	0.0267	0.0000	0.0089	0.0000	964873200.0000	0.0800
2	0.0000	0.0000	0.0683	0.0000	0.0000	0.0000	823486400.0000	0.0683
3	0.0000	0.0000	0.0000	0.5779	0.0000	0.0000	6966757600.0000	0.5779
4	0.0000	0.0055	0.0000	0.0000	0.0273	0.0055	461048400.0000	0.0382
5	0.0000	0.0181	0.0725	0.0000	0.0181	0.1268	2839874400.0000	0.2356
Total	0.0000	0.0680	0.1675	0.5779	0.0543	0.1323	12056040000.0000	
Area	0	820356601	2018918308	6966757600	654980296	1595027196	12056040000	
SE	0.0000	0.0236	0.0341	0.0000	0.0214	0.0343		
SE area	0	284241545	411125566	0	257769140	413959361		
95% CI area	0	557113429	805806110	0	505227515	811360348		
PA [%]	nan	65.3424	40.7885	100.0000	50.2794	95.8707		
UA [%]	nan	55.5556	100.0000	100.0000	71.4286	53.8462		
Kappa hat	nan	0.5231	1.0000	1.0000	0.6979	0.4681		
Precisión total [%] =84.4786								
Clasificación Kappa =0.7480								
Area unit = metre^2								
SE = standard error								
CI = confidence interval								
PA = producer's accuracy								
UA = user's accuracy								

Figure 29. Matriz de confusión de caso 2 (Máxima probabilidad)

I.II.III. ÁNGULO ESPECTRAL

ErrMatrixCode	Referencia	Classified	PixelSum					
8	1	1	8.0					
11	1	4	1.0					
14	2	1	3.0					
15	2	2	9.0					
22	3	3	24.0					
26	4	1	1.0					
29	4	4	3.0					
30	4	5	3.0					
35	5	4	3.0					
36	5	5	6.0					
> ERROR MATRIX (pixel count)								
> Referencia								
V_Classified	0	1	2	3	4	5	Total	
0	0	0	0	0	0	0	0	
1	0	8	3	0	1	0	12	
2	0	0	9	0	0	0	9	
3	0	0	0	24	0	0	24	
4	0	1	0	0	3	3	7	
5	0	0	0	0	3	6	9	
Total	0	9	12	24	7	9	61	
> AREA BASED ERROR MATRIX								
> Referencia								
V_Classified	0	1	2	3	4	5	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	215382800.0000	0.0179
1	0.0000	0.1341	0.0503	0.0000	0.0168	0.0000	2425092800.0000	0.2012
2	0.0000	0.0000	0.0962	0.0000	0.0000	0.0000	1159836000.0000	0.0962
3	0.0000	0.0000	0.0000	0.5586	0.0000	0.0000	6733973200.0000	0.5586
4	0.0000	0.0033	0.0000	0.0000	0.0099	0.0099	277249600.0000	0.0230
5	0.0000	0.0000	0.0000	0.0000	0.0344	0.0688	1244505600.0000	0.1032
Total	0.0000	0.1374	0.1465	0.5586	0.0610	0.0787	12056040000.0000	
Area	0	1656335619	1766109200	6733973200	735747524	948491657	12056040000	
SE	0.0000	0.0288	0.0263	0.0000	0.0245	0.0178		
SE area	0	346955788	316615853	0	294958137	214847628		
95% CI area	0	680033345	620567071	0	578117948	421101351		
PA [%]	nan	97.6088	65.6718	100.0000	16.1497	87.4726		
UA [%]	nan	66.6667	100.0000	100.0000	42.8571	66.6667		
Kappa hat	nan	0.6136	1.0000	1.0000	0.3914	0.6382		
Precisión total [%] =86.7534								
Clasificación Kappa =0.7920								
Area unit = metre^2								
SE = standard error								
CI = confidence interval								
PA = producer's accuracy								
UA = user's accuracy								

Figure 30. Matriz de confusión de caso 2 (Ángulo espectral)

I.III. CASO 3

I.III.I. DISTANCIA MÍNIMA

ErrMatrixCode	Referencia	Classified	PixelSum						
7	1	1	7.0						
8	1	2	1.0						
10	1	4	1.0						
12	1	6	1.0						
14	2	2	10.0						
19	3	1	1.0						
21	3	3	6.0						
22	3	4	3.0						
26	4	2	6.0						
28	4	4	8.0						
35	5	5	7.0						
42	6	6	12.0						
> ERROR MATRIX (pixel count)									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Total	
0	0	0	0	0	0	0	0	0	
1	0	7	0	1	0	0	0	8	
2	0	1	10	0	6	0	0	17	
3	0	0	0	6	0	0	0	6	
4	0	1	0	3	8	0	0	12	
5	0	0	0	0	0	7	0	7	
6	0	1	0	0	0	0	12	13	
Total	0	10	10	10	14	7	12	63	
> AREA BASED ERROR MATRIX									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.0872	0.0000	0.0125	0.0000	0.0000	0.0000	1200883200.0000	0.0996
2	0.0000	0.0217	0.2172	0.0000	0.1303	0.0000	0.0000	4450936800.0000	0.3692
3	0.0000	0.0000	0.0000	0.0353	0.0000	0.0000	0.0000	425003200.0000	0.0353
4	0.0000	0.0181	0.0000	0.0542	0.1445	0.0000	0.0000	2613356000.0000	0.2168
5	0.0000	0.0000	0.0000	0.0000	0.0000	0.0403	0.0000	485258000.0000	0.0403
6	0.0000	0.0184	0.0000	0.0000	0.0000	0.0000	0.2206	2880602800.0000	0.2389
Total	0.0000	0.1453	0.2172	0.1019	0.2748	0.0403	0.2206	12056040000.0000	
Area	0	1751957109	2618198118	1228452600	3313156204	485258000	2659017969	12056040000	
SE	0.0000	0.0359	0.0454	0.0309	0.0538	nan	0.0184		
SE area	0	433140354	547635427	372756318	648644334	0	221584831		
95% CI area	0	848955094	1073365436	730602384	1271342894	0	434306268		
PA [%]	nan	59.9771	100.0000	34.5966	52.5854	100.0000	100.0000		
UA [%]	nan	87.5000	58.8235	100.0000	66.6667	100.0000	92.3077		
Kappa hat	nan	0.8537	0.4740	1.0000	0.5403	1.0000	0.9013		
Precisión total [%] =74.4895									
Clasificación Kappa =0.6762									
Area unit = metre^2									
SE = standard error									
CI = confidence interval									
PA = producer's accuracy									
UA = user's accuracy									

Figure 31. Matriz de confusión de caso 3 (Distancia mínima)

I.III.II. MÁXIMA PROBABILIDAD

ErrMatrixCode	Referencia	Classified	PixelSum						
7	1	1	8.0						
11	1	5	1.0						
14	2	2	4.0						
16	2	4	5.0						
21	3	3	5.0						
22	3	4	2.0						
26	4	2	3.0						
28	4	4	11.0						
35	5	5	6.0						
40	6	4	2.0						
41	6	5	1.0						
42	6	6	11.0						
> ERROR MATRIX (pixel count)									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Total	
0	0	0	0	0	0	0	0	0	
1	0	8	0	0	0	0	0	8	
2	0	0	4	0	3	0	0	7	
3	0	0	0	5	0	0	0	5	
4	0	0	5	2	11	0	2	20	
5	0	1	0	0	0	6	1	8	
6	0	0	0	0	0	0	11	11	
Total	0	9	9	7	14	6	14	59	
> AREA BASED ERROR MATRIX									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	0.0000	0.1153	0.0000	0.0000	0.0000	0.0000	0.0000	1390176400.0000	0.1153
2	0.0000	0.0000	0.0361	0.0000	0.0271	0.0000	0.0000	761027200.0000	0.0631
3	0.0000	0.0000	0.0000	0.0002	0.0000	0.0000	0.0000	2153600.0000	0.0002
4	0.0000	0.0000	0.1295	0.0518	0.2850	0.0000	0.0518	6246335200.0000	0.5181
5	0.0000	0.0124	0.0000	0.0000	0.0000	0.0746	0.0124	1199593200.0000	0.0995
6	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.2038	2456754400.0000	0.2038
Total	0.0000	0.1277	0.1656	0.0520	0.3120	0.0746	0.2680	12056040000.0000	
Area	0	1540125550	1996456486	626787120	3761638874	899694900	3231337070	12056040000	
SE	0.0000	0.0124	0.0530	0.0357	0.0605	0.0163	0.0378		
SE area	0	149949150	639275011	429902272	729303216	196329523	455302879		
95% CI area	0	293900334	1252979021	842608453	1429434304	384805865	892393642		
PA [%]	nan	90.2638	21.7822	0.3436	91.3295	100.0000	76.0290		
UA [%]	nan	100.0000	57.1429	100.0000	55.0000	75.0000	100.0000		
Kappa hat	nan	1.0000	0.4864	1.0000	0.3459	0.7298	1.0000		
Precisión total [%] =71.4923									
Clasificación Kappa =0.6205									
Area unit = metre^2									
SE = standard error									
CI = confidence interval									
PA = producer's accuracy									
UA = user's accuracy									

Figure 32. Matriz de confusión de caso 3 (Máxima probabilidad)

I.III.III. ÁNGULO ESPECTRAL

ErrMatrixCode	Referencia	Classified	PixelSum						
9	1	1	8.0						
11	1	3	1.0						
17	2	2	9.0						
19	2	4	1.0						
21	2	6	1.0						
25	3	3	6.0						
26	3	4	1.0						
31	4	2	3.0						
33	4	4	14.0						
34	4	5	2.0						
37	5	1	1.0						
38	5	2	3.0						
41	5	5	5.0						
42	5	6	2.0						
49	6	6	3.0						
> ERROR MATRIX (pixel count)									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Total	
0	0	0	0	0	0	0	0	0	
1	0	8	0	0	0	1	0	9	
2	0	0	9	0	3	3	0	15	
3	0	1	0	6	0	0	0	7	
4	0	0	1	1	14	0	0	16	
5	0	0	0	0	2	5	0	7	
6	0	0	1	0	0	2	3	6	
Total	0	9	11	7	19	11	3	60	
> AREA BASED ERROR MATRIX									
> Referencia									
V_Classified	0	1	2	3	4	5	6	Area	Wi
0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	2259857200.0000	0.1874
1	0.0000	0.0893	0.0000	0.0000	0.0000	0.0112	0.0000	1211835600.0000	0.1005
2	0.0000	0.0000	0.1699	0.0000	0.0566	0.0566	0.0000	3413633600.0000	0.2831
3	0.0000	0.0096	0.0000	0.0577	0.0000	0.0000	0.0000	811364800.0000	0.0673
4	0.0000	0.0000	0.0179	0.0179	0.2511	0.0000	0.0000	3459202400.0000	0.2869
5	0.0000	0.0000	0.0000	0.0000	0.0161	0.0402	0.0000	679240800.0000	0.0563
6	0.0000	0.0000	0.0031	0.0000	0.0000	0.0061	0.0092	220905600.0000	0.0183
Total	0.0000	0.0990	0.1909	0.0756	0.3238	0.1141	0.0092	12056040000.0000	
Area	0	1193096457	2301197910	911655693	3903597620	1376182320	110452800	12056040000	
SE	0.0000	0.0147	0.0413	0.0203	0.0403	0.0341	0.0041		
SE area	0	177665831	497857353	245310947	485923248	411300104	49395994		
95% CI area	0	348225029	975800412	480809456	952409565	806148204	96816148		
PA [%]	nan	90.2850	89.0050	76.2849	77.5388	35.2549	100.0000		
UA [%]	nan	88.8889	60.0000	85.7143	87.5000	71.4286	50.0000		
Kappa hat	nan	0.8767	0.5056	0.8455	0.8151	0.6775	0.4954		
Precisión total [%] =61.7388									
Clasificación Kappa =0.5398									
Area unit = metre^2									
SE = standard error									

Figure 33. Matriz de confusión de caso 3 (Ángulo espectral)